



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

(An 3, semesterul 2)

Curs 1: Introducere



Info

Evaluare

Examen scris – 50% din nota (nota minima 5)

Laborator + proiect – 50% din nota (nota minima 5)

Prezenta la laborator/proiect – obligatorie!

Laborator – evaluare dupa fiecare laborator + teste

Proiect – evaluare dupa fiecare faza de proiectare (specifice, analiza, design logic, implementare, testsare si validare).

Documentatii (curs & laborator)

<http://users.utcluj.ro/~tmarita/IPL/IPCurs/IPCurs.htm>

<http://users.utcluj.ro/~tmarita/IPL/IPLab/IPLAB.htm>

Retea Dorobantilor 71-73: \\D110-13\Users\Public\Public Documents\PI

Paginile personale ale lectorilor / indrumatorilor de laborator

<http://www.cv.utcluj.ro/home.html>



Bibliografie curs

- R.C.Gonzales, R.E.Woods, *Digital Image Processing – 2-nd Edition*, Prentice Hall, 2002.
- E. Trucco, A. Verri, *Introductory Techniques for 3-D Computer Vision*, Prentice Hall, 1998.
- W.K. Pratt, *Digital Image Processing: PIKS Inside, 3-rd Edition*, Wiley & Sons 2001.
- G. X.Ritter, J.N. Wilson, *Handbook of computer vision algorithms in image algebra - 2nd ed*, CRC Press, 2001.
- Frank Y. Shih, *Image Processing And Pattern Recognition - Fundamentals and Techniques*, Wiley & Sons, Hoboken, New Jersey, 2010.
- A. Koschan, M. Abidi, *Digital Color Image Processing*, Wiley & Sons, 2008.
- H.C. Lee, *Introduction to Color Image Science*, Cambridge University Press 2005
- D. Forsyth, J. Ponce, *Computer Vision. A Modern Approach*, Prentice Hall, 2002.
- L. G. Shapiro, G. C. Stockman, *Computer Vision*, Prentice Hall, 2000

Bibl. UTCN:

- S.Nedevschi, "Prelucrarea imaginilor si recunoasterea formelor", *Ed. Microinformatica*, 1997.
- S. Nedevschi, R. Dănescu, F. Oniga, T. Marița, *Tehnici de viziune artificială aplicate în conducerea automată a autovehiculelor*, Editura U.T. Press, Cluj-Napoca, 2012.
- S. Nedevschi, T. Marița, R. Dănescu, F. Oniga, R. Brehar, I. Giosan, C. Vicaș, *Procesarea Imaginilor - Îndrumător de laborator*, Editura U.T. Press, Cluj-Napoca, 2013.
- S. Nedevschi, T. Marita, R. Danescu, F. Oniga, R. Brehar, I. Giosan, S. Bota, A. Ciurte, A. Vatavu, „Image Processing - Laboratory Guide”, UTPress Edition, 2016, ISBN 978-606-737-137-6, <http://biblioteca.utcluj.ro/carti-online.html>



Viziunea artificiala

Vizunea artificiala (Computer Vision)?

Viziunea artificiala este un domeniu/disciplina care **infereaza date/informatie din imagini** cu ajutorul **metodelor matematice, geometrice, statistice, ale fizicii si a teoriei invatarii automate** (machine learning)

Se bazeaza pe:

- Cunoasterea profunda a modelului camerei si al procesului de formare al imaginii pentru a obtine inferente simple de la valorile pixelilor individuali pana la combinarea informatiei de la imagini multiple pentru a obtine un tot unitar coerent
- Impunerea anumitor **ordonari asupra unor grupe de pixeli** pentru ai **separa sau grupa intre ei** sau pentru a **infera informatia de forma si a recunoaste obiecte** pe baza trasaturilor geometrice.

Alte denumiri

- analiza de imagini (image analysis)
- analiza scenei (scene analysis)
- interpretarea imaginilor (image understanding)



Viziunea artificiala

Disipline conexe

- Inteligența artificială (artificial intelligence)
- Robotica (robotics)
- Procesarea semnalelor (signal processing)
- Recunoașterea de forme (pattern recognition)
- Teoria controlului (control theory)
- Psihologia (psychology)
- Neuroștiințele (neuroscience)

Subdomenii:

- Procesarea imaginilor
- Recunoașterea formelor
- Fotogrametria (discipline care se ocupa cu inferarea informației metrice /masuratori: calibrarea camerelor, stereoviziunea, reconstrucția 3D detectia de obiecte)
- Analiza statică/dinamică a imaginilor, trasaturilor, obiectelor



Procesarea imaginilor

Procesarea imaginilor (Image Processing)

- Se ocupa cu *studiul proprietatilor imaginilor* si cu *transformarea acestora* (a imaginilor)
- Majoritatea algoritmilor de viziune artificiala necesita folosirea unor algoritmi de procesare a imaginilor

Example de metode:

- imbunatatirea calitatii imaginilor (*image enhancement*) – prin transformarea imaginilor: punerea in evidenta a detaliilor ascune/obscure, a trasaturilor de interes
- *compresia* (reprezentare compacta a imginilor/secventelor pentru transmisie / stocare)
- *restaurarea* (eliminarea elementelor de degradare cunoscute / modelabile)
- *extragerea de trasaturi* (localizarea anumitor sabloane – ex: muchii, colturi, structuri complexe - obiecte)



Viziunea artificiala

Domenii de cercetare:

- Detectia de trasaturi (Feature Detection)
- Representarea conturelor (Contour Representation)
- Analiza imaginilor de profunzime (Range image analysis)
- Modelarea si reprezentarea formelor (Shape modeling and representation)
- Stereo viziunea (Stereo vision)
- Viziunea color (Color vision)
- Vizunea activa (Active/Purposive vision)
- Invarianti (Invariants)
- Detectia obiectelor (Object detection)
- Analiza miscarii (Motion analysis)
- Urmarirea miscarii obiectelor (Tracking)
- Recunoasterea obiectelor 3D (3D object recognition)
- Adnotarea semantica a imaginilor/video (Image annotation)
- Aritectura sistemelor de viziune (Vision architectures)



Viziunea artificiala

Domenii de aplicare


- Inspectie industrială / controlul calitatii (Industrial inspection/quality control)
- Inginerie inversa (reverse engineering)
- Supraveghere si securitate (Surveillance and security)
- Aplicatii biometrice:recunoastera fetei (Face recognition), amprentelor ..)
- Interactiune om-calculator: recunoasterea gesturilor (Gesture recognition)
- Monitorizarea traficului (Road monitoring)
- Aplicatii spatiale (Space applications)
- Analiza imaginilor medicale (Medical image analysis)
- Realitate virtuala / augmentata, teleprezenta si telerobotica (Virtual / augmented reality, telepresence, and telerobotics)
- Vehicule autonome (Autonomous vehicles)
- Cartografiere automata, achizitie automata de modele (Automated map making, model acquisition)



Viziunea artificiala

Date de intrare

- Imagini captate cu dispozitive de achizitie adaptate pentru intregul spectru frecventa al *undelor electromagnetice*






Viziunea artificială

Date de intrare




Spectrul vizibil (380 – 750 nm)




Reflectivitatea LiDAR
(NIR : 0.75 .. 1.4μm)



Reflectivitatea RADAR
24GHz (SRR) / 77 (LRR)



LWIR / Thermal (8-15μm)



LWIR / Thermal (heatmap)



Viziunea artificiala

Date de intrare


Alte surse de imagini: *unde acustice (US / ecografii), RMN, CT*



US 7–18 MHz: muschi, tiroida, ..
US 1–6 MHz: ficat, rinichi, ...



X-ray (radiografie)



MRI (RMN)



X-ray (CT slice)





Exemple de procesări simple

Conversii Color - Nivele de gri – Imagine binară



Negativ





Exemple de procesări simple

Modificare strălucire și contrast



Luminozitate ++




Imaginea sursa



Contrast ++



Luminozitate --




Contrast --



Exemple de procesări simple

Eliminarea zgomotului



Imagine corupta de zgomot
de tip sare și piper




Imagine filtrata: filtru median




Exemple de procesări simple

Eliminarea zgomotului



Imagine corupta de Zgomot Gaussian




Imagine filtrata: filtru Gaussian



Exemple de procesări simple

Calculul gradientului – măsura variațiilor din imagine




Modulul (magnitudinea gradientului)



Exemple de procesări simple

Determinarea punctelor de muchie



Rezultatul aplicarii alg. Canny (cubtiere + binarizare cu histereza)


Technical University of Cluj Napoca

Computer Science Department



Exemple de procesări simple

Operații pe imagini binare - dilatare





Exemple de procesări simple

Operații pe imagini binare - eroziune





Exemple de procesări simple


Dilatare + eroziune = închidere, umplerea golurilor cu păstrarea conturului exterior neschimbat





Exemple de procesări simple



Identificarea obiectelor individuale din imagini binare -
etichetarea





Exemple de procesari complexe

Segmentare si analiza de imagini medicale



Features

The features extracted from the abnormal nuclei found in the image are:

Nucleus	Entropy	Homogeneity	Coarseness	Busyness	Fractal dimension	No. clusters	No. colors
0	2.53647	0.450885	0.0131579	0.661315	1.96163	20	2441
1	2.57566	0.404834	0.0227273	0.611727	4.71926	12	1027
2	2.78164	0.438416	0.013245	0.660755	2.14959	19	2436
3	2.47713	0.454494	0.0168067	0.639943	4.65406	16	1230
4	2.51205	0.435782	0.016	0.644344	2.2737	16	1548
5	2.48444	0.442439	0.018018	0.633624	4.3415	12	1310

The execution times for the operation mentioned below are:

Operation	Time elapsed
KSW on RGB	00:00:735
KSW and Minimum Error	00:04:422
MultiSpace thresholding	00:02:156
HMT	00:00:390
Texture-related features	00:13:750




Segmentare imagini



Image



Base



Final

Materials Detected:
Sky
Building
Water
No. of segments merged: 14



Image



Base



Final



Materials

Materials Detected:
Building
Sky
Tree
Road
No. of segments merged: 89



Image



Base



Final



Materials


Materials Detected:
Tree
Sky
Building
Road
Grass
No. of segments merged: 33



Stereoviziune densa




Imagine camera
stanga (grayscale)




Harta de adancime




Estimarea fluxului optic




Yosemite frame 0



Yosemite frame 1



Yosemite GT flow



flow color coding

Exemplificare a rezultatului codificarii fluxului de miscare in conformitate cu conventia de culoare Middleburry [4]:
Hue – directia / Saturatia – amplitudinea (similar cu codificarea culorilor in modelul HIS)





Exemple de aplicatii

Detectie obiecte si drum in scenarii de trafic





Exemple de aplicatii

Object Attributes

Obj ID	Points	XMin	XMax	YMin	YMax	ZMin	ZMax	TrackingID	SpeedX	SpeedZ
0	77	2397	4197	-1702	-317	70012	74012	379	-0.1	119.7
1	41	2168	4068	-1920	-558	138265	148765	382	0.9	147.7

Left Image [1:1] (634,226,[70],[GM: 2])

View Points

View:

Points: 3597 Objects: 2 (Tracking)

-43520 (X:55886, Z:145350) 58239



164761

-6407



Exemple de aplicatii

Detectie si clasificare obiecte, marcaje de pe drum etc. in scenarii de trafic





Proiecte de cercetare in domeniu

Image Processing and Pattern Recognition Group

<http://www.cv.utcluj.ro/research.72.html>

Driving Assistance Systems

SCABOR, DESBOR, DESPED, PERSENS: <http://www.cv.utcluj.ro/scabor.html>

Intrsafe FP7 project: <http://www.cv.utcluj.ro/intersafe-2.html>

Optical Flow: <http://www.cv.utcluj.ro/optical-flow.html>

Medical Imaging

<http://www.cv.utcluj.ro/tdii.html>

<http://www.cv.utcluj.ro/focal-liver-diseases.html>

<http://www.cv.utcluj.ro/adkp-detection.html>

Etc.



Procesarea imaginilor

Discipline conexe in ani superiori

Licenta

- Sisteme de recunoastere a formelor (an 4 CA)
- Interactiune om-calculator (an 4 TI)

Master




- Viziune Artificiala (an 1 – toate specializarile)
- Viziune Artificiala pentru roboti mobili (an 2 – IVA)
- Interfete om-calculator (an 2 – IC)

MODELUL CAMEREI SI PROCESUL DE FORMARE A IMAGINII


Scop:

- prezentarea principalilor parametri ai sistemelor de achiziție (camere)
- principiile procesului de formare a imaginilor.

Elementele de bază ale unei camere de luat vederi




Obiectiv (ansamblu lentile):




Senzor:

Parametrii dispozitivului senzorial



Dimensiuni standard ale senzorilor din camerele de luat vederi



Parametrii senzorului CCD/CMOS respectiv a imaginii în memorie

Parametrii senzorului:

S_x – lățimea dispozitivului CCD [mm] (valorile standard sunt prezentate în figura de mai sus);

S_y – înălțimea dispozitivului CCD [mm] (valorile standard sunt prezentate în figura de mai sus);

N_{cx} – numărul elementelor senzoriale pe direcția orizontală;

N_{cy} – numărul elementelor senzoriale pe direcția verticală;

dx – distanța dintre centrele a două elemente senzoriale consecutive pe direcție orizontală:

$$dx = S_x / N_{cx}$$

dy - distanța dintre centrele a două elemente senzoriale consecutive pe direcție verticală:

$$dy = S_y / N_{cy}$$

$N_x \times N_y$ – rezoluția spațială

Parametrii imaginii (din memorie / framegrabber):

N_{fx} – numărul de pixeli în direcția orizontală, prin scalarea / eșantionarea unei linii de imagine orizontală de către computer / framegrabber;

N_{fy} – numărul de pixeli în direcția verticală


dpx – dimensiunea orizontală efectivă a unui pixel din memorie: $dpx = dx * N_{cx} / N_{fx}$;

dpy – dimensiunea verticală efectivă a unui pixel din memorie: $dpy = dy * N_{cy} / N_{fy}$;


N_{cx} / N_{fx} – factorul de scalare / eșantionare a liniilor de imagine orizontale.

Tipuri de senzori

Senzori CCD (Charged Coupled Device)



Senzori CMOS



Example camera/frame grabbers:

- camera analogical: <http://www.stemmer-imaging.co.uk/en/products/series/jai-a1/>
- frame grabber analogic: <http://www.stemmer-imaging.co.uk/en/products/series/dalsa-pc2-comp/>
- frame grabber digital (Camera Link): <http://www.silicon-software.info/en/products/98-me4-ad4-cl-en.html>
- camera digitala (Camera Link): <http://www.stemmer-imaging.co.uk/en/products/series/jai-a10/>
- camera digitala (Giga E sau USB): <http://www.stemmer-imaging.co.uk/en/products/series/ids-ueye-se/>

Transferul imaginilor

Camera (iesire analogica/digitala) $\Rightarrow$ Frame Grabber (imagine digitala)

Standarde dedicate de transmisie digitala (camere):

- GigaE Vision: 1Gbps, (Gigabit Ethernet protocol), Cabluri low cost (CAT5e or CAT6), 100m distanta
- Camera Link: 1.2Gbps (base) ... 3.6Gbps (full)
- RS 422 / EIA-644 (LVDS): 655Mbps
- IEEE 1394: 400 Mbps / 800 Mbps
- USB 3.0: 3.2 Gbps
- USB 2.0: 480 Mbps
- USB 1.1 :12 mbps

Diagram 10: 8-bit digital video.





Diagram 9: Equivalence between analog composite and digital video



CMOS vs. CCD




TABLE 1

Comparison of CCD and CMOS Image Sensor Features

CCD

Smallest pixel size

Lowest noise

Lowest dark current

~100% fill factor for full-frame CCD

Established technology market base

Highest sensitivity

Electronic shutter without artifacts

CMOS

Single power supply

Single master clock

Low power consumption

X, Y addressing and subsampling


Smallest system size

Easy integration of circuitry


Senzori color

a) Bayer mask



For color photos, the majority of commercial digital color cameras use pixels covered with special color filters in the three primary colors red, green and blue.



b) Filter wheel



c) 3-CCD camera



4) Foveon X3 sensor

<http://www.foveon.com/article.php?a=67>

http://www.foveon.com/files/ccd_vs_x3_photondropv5.swf

http://www.foveon.com/files/image_comparisonv2_2.swf

http://en.wikipedia.org/wiki/Foveon_X3_sensor

Tutoriale senzori (tema de casa - studiu individual)

JAI 3CCD vs Bayer color presented by STEMMER IMAGING:


<https://www.youtube.com/watch?v=2D9DkVDcUeU>

Digital Camera Sensor Technology - Part 2. The Image Processing Pipeline:


<https://www.youtube.com/watch?v=NJUw48PCRWI>

Digital Camera Sensor Technology - Part 3 CCD Sensors explained:

<https://www.youtube.com/watch?v=Xkput-1xNYE>



Decodificarea pattern-ului Bayer




Calitatea imaginii (Bayer pattern vs. 3CCD) - JAI 3CCD vs Bayer color presented by STEMMER IMAGING: <https://www.youtube.com/watch?v=2D9DkVDcUeU>


Formatul de reprezentare a imaginilor

- rezolutia spatiala : $N_X \times N_Y$ (Width x Height)
- rezolutia / adâncimea de culoare := numarul de culori/nuanțe codificate intr-un pixel

$n = 1, 4, 8, 16, 24, 32 \dots$ Biti / pixel $\Rightarrow 2^n$ culori / nuante



Structura fisier bitmap cu paleta de culori/nuante (1, 4, 8 biti/pixel)



Structura fisier bitmap RGB24 (24 biti/pixel)

Reprezentarea culorilor / nuanțelor

Modelul de culoare RGB



RGB $\Rightarrow$ Culoarea fiecărui pixel (atât pentru echipamentele de achiziție – camere) cât și pentru afișare (TV, CRT, LCD) se obține prin combinația a trei culori primare: **roșu**, **verde** și **albastru**

(**Red**, **Green** și **Blue**)


$\Rightarrow$ spațiu de culoare aditiv (**R**+**G**+**B** $\Rightarrow$ **Alb**)

Imagini “grayscale” /monocrome:

$R = G = B$ (diagonal principala a cubului)



Modelul de culoare RGB mapat pe un cub. În acest exemplu fiecare culoare este reprezentată pe câte 8 biți (256 de nivele) (imagini bitmap RGB24). Numărul total de culori este $2^8 \times 2^8 \times 2^8 = 2^{24} = 16.777.216$.



Reprezentarea culorilor / nuanțelor


Modelul de culoare CMY

CMY: spațiu de culoare complementar față de RGB folosit la dispozitive de imprimare color (plotere / imprimante)

CMY model diferential ("subtractive"):

Alb = absenta componentelor de culoare

Negru = C + M + Y




Modelul de culoare CMYK



Ce este o imagine?

Imaginea ca funcție $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x, y) = g$

- Imaginea poate fi văzută ca o suprafață cu înălțimi variabile (forme de relief)




<https://s3.amazonaws.com/content.udacity-data.com/courses/ud810/slides/Unit-2/2A-L1.pdf>

Imaginea color ca funcție $f: \mathbb{R}^2 \rightarrow \mathbb{R}^3$

- Trei funcții independente, pentru fiecare componenta de culoare, definite pe (x, y) :


$$f(x, y) = \begin{pmatrix} r(x, y) \\ g(x, y) \\ b(x, y) \end{pmatrix}$$

Domenii de utilizare



Procesul de formare a imaginii


Modelul cu „lentile subțiri”



Constrângerile modelului [Trucco1998]:

1. Orice rază optică care intră prin lentilă paralelă cu axa optică, va trece pe cealaltă parte prin punctul focal;
2. Orice rază optică care intră în lentilă trecând prin punctul focal va emerge paralelă cu axa optică;
3. Raza optică care intră în lentilă trecând prin centrul O al acesteia, nu își va schimba traiectorie la ieșire. Acest tip rază se numește rază principală.

Focalizarea imaginii



Obținerea unei imagini focalizate:

1. Prin reducerea diametrului aperturii / diafragmei la un punct (camera așa numită „pinhole): [model teoretic](#)
2. Prin introducerea unui [sistem optic \(obiectiv\)](#) compus din lentile, diafragme și alte componente, proiectat pentru a face ca toate razele optice care își au originea de la același punct 3D din scenă să convergă într-un punct unic pe planul imagine.

- Cercul de confuzie (c)


Imagine defocalizata: proiecția cercului de confuzie pe planul imagine > 1 pixel;

Imagine focalizata: proiecția cercului de confuzie pe planul imagine < 1 pixel;


- Adâncime de focalizare: $\pm D_1$ pt. care avem imagine focalizata

Analogii legate de vederea umana

<http://ro.wikipedia.org/wiki/Miopie>




<http://ro.wikipedia.org/wiki/Hipermetropie>



Modelul perspectivă (pinhole) al camerei

Apertura / diafragma sunt approximate cu un punct (centrul de proiecție) $\Rightarrow$ principiul coliniarității modelului cu lentile subțiri (constrângerea 3)



Ecuatiile fundamentale ale modelului perspectivă al camerei sunt [Trucco1998]:

$$\begin{cases} x = f \cdot \frac{X_C}{Z_C} \\ y = f \cdot \frac{Y_C}{Z_C} \end{cases}$$


Unde: $[X_C, Y_C, Z_C]$ sunt coordonatele punctului **P** în sistemul de coordonate al camerei

$[x, y, -f]$ sunt coordonatele punctului **p** în sistemul de coordonate al camerei

Parametrii fizici ai camerelor

Parametrii intrinseci – descriu caracteristicile optice și geometrice ale camerei (caracteristicile interne ale camerei):

- *distanța focală* – distanța dintre centrul optic al sistemului de lentile al obiectivului și planul imagine: f ;
- *punctul principal* – coordonatele centrului real al imaginii (intersecția axei optice a obiectivului cu planul imagine) în coordonate imagine (pixeli) : (u_0, v_0) ;
- *coeficienții de distorsiune radială și tangențială* ai lentilelor obiectivului.



Transformarea de coordonate dintre sistemul de referință al camerei și planul imagine (proiecție / normalizare) : $\mathbf{P} = [X_C, Y_C, Z_C]^T$ [unit. metrice] $\Rightarrow \mathbf{p} = [u, v]^T$ [pix]

1. Transformarea $\mathbf{P} = [X_C, Y_C, Z_C]^T$ [m sau mm] $\Rightarrow \mathbf{p} = [x, y, -f]^T$ [m sau mm]

Sistemul ecuațiilor fundamentale ale modelului pinhole: pentru coordonate normalizate (cu $1/Z$):

$$\begin{bmatrix} x \\ y \end{bmatrix} = f \begin{bmatrix} X_C / Z_C \\ Y_C / Z_C \end{bmatrix} = f \begin{bmatrix} x_N \\ y_N \end{bmatrix} \quad (1)$$

f – distanța focală [unit. metrice]

x_N, y_N - coordonate normalizate (cu $1/Z$):

2. Transformarea coordonatelor punctului $\mathbf{p}$ din unități metrice $[x, y]^T$ în coordonate imagine $[u, v]^T$ [pix]

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} D_u \cdot x \\ D_v \cdot y \end{bmatrix} + \begin{bmatrix} u_0 \\ v_0 \end{bmatrix} \quad (2)$$

D_u, D_v – coeficienți de transformare unități metrice în pixeli:

$D_u = 1 / dpx; D_v = 1 / dpy;$

(1) + (2) $\Rightarrow$ ecuația de proiecție:

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = A \cdot \begin{bmatrix} x_N \\ y_N \\ 1 \end{bmatrix} \quad (3)$$

$$A = \begin{bmatrix} f_x & 0 & u_0 \\ 0 & f_y & v_0 \\ 0 & 0 & 1 \end{bmatrix} \text{ matricea internă a camerei}$$

f_x – distanța focală exprimată în unități de pixeli orizontali: $f_x = f \cdot D_u = \frac{f}{dpx}$

f_y – distanța focală exprimată în unități de pixeli verticali: $f_y = f \cdot D_v = \frac{f}{dpy}$

Transformarea inversă din coordonatele imagine în sistemul de coordonate al camerei (*reconstrucție*): $\mathbf{p} = [u, v]^T \text{ [pix]} \Rightarrow \mathbf{P} = [X_C, Y_C, Z_C]^T \text{ [unit. metrice]}$

$$\begin{bmatrix} x_N \\ y_N \\ 1 \end{bmatrix} = A^{-1} \cdot \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \quad (4)$$


OBSERVATIE: Cu o singura camera nu putem determina Z (adâncimea), doar coordonatele normalizate (ecuația dreptei de proiecție):

$$\begin{bmatrix} x_N \\ y_N \end{bmatrix} = \begin{bmatrix} X_C / Z_C \\ Y_C / Z_C \end{bmatrix} \quad (5)$$

Pentru determinarea adâncimii: minim 2 camere (sistem stereo).

Modelarea distorsiunilor lentilelor

Distorsiunea radiala (curbura lentilelor)



$$\begin{bmatrix} \partial x^r \\ \partial y^r \end{bmatrix} = \begin{bmatrix} x \cdot (k_1 \cdot r^2 + k_2 \cdot r^4 + \dots) \\ y \cdot (k_1 \cdot r^2 + k_2 \cdot r^4 + \dots) \end{bmatrix}$$

$$r^2 = x^2 + y^2;$$

$k_1, k_2, \dots$ - coeficienții de distorsiune radială

Distorsiunea tangențiala (nealinierea centrelor de curbura a lentilelor)

$$\begin{bmatrix} \partial x^t \\ \partial y^t \end{bmatrix} = \begin{bmatrix} 2p_1 \cdot xy + p_2(r^2 + 2x^2) \\ p_1(r^2 + 2y^2) + 2p_2 \cdot xy \end{bmatrix}$$

p_1, p_2 – sunt coeficienții de distorsiune tangentiala.

Transformarea coordonatelor punctului $\mathbf{p}$ din **unități metrice** $[x, y]^T$ in coordonate imagine $[u, v]^T$ [pix]:

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} D_u \cdot (x + \partial x^r + \partial x^t) \\ D_v \cdot (y + \partial y^r + \partial y^t) \end{bmatrix} + \begin{bmatrix} u_0 \\ v_0 \end{bmatrix} \quad (6)$$

OBSERVATIE: Ec de proiecție (6) devine neliniară !!!

Soluția: corecție distorsiuni pe imagine $\Rightarrow$ proiectie folosind modelul liniar.

Corecția distorsiunilor lentilelor


- Gradul de degradare al imaginilor datorat distorsiunii lentilelor este proporțional cu valoarea coeficienților.
- Valoarea acestor coeficienți depinde de calitatea lentilelor, curbura lentilelor (distanța focală) etc.
- Ponderea cea mai mare în degradarea imaginii o au componentele radiale.
- În tabelul următor se prezintă valorile medii ale acestor coeficienți pentru obiectivele CCTV Pentax-Cosmicar testate în diverse experimentele de calibrarea camerelor:

Distanța focală [mm]	Coeficienți de distorsiune			
	k_1	k_2	p_1	p_2
16 mm	-0.1420	-0.1190	0.0004	0.0014
8.5 mm	-0.2070	0.2780	0.0018	-0.0011
6.5 mm	-0.2100	0.1200	0.0020	0.0007




Valori medii ale coeficienților de distorsiune obținuți prin calibrare pentru obiective CCTV Pentax-Cosmicar cu diverse distanțe focale.

Efectul de degradare se manifestă prin deplasarea poziției punctelor proiectate pe imagine de-a lungul unor direcții radiale (cu centrul în punctul principal al imaginii) cu o valoare $\partial \mathbf{r} = [\partial x \ \partial y]^T$. Acest efect este neglijabil pentru pixelii centrali și se accentuează pentru pixelii de la periferia imaginii :

$$\begin{bmatrix} \partial x \\ \partial y \end{bmatrix} = \begin{bmatrix} \partial x^r + \partial x^t \\ \partial y^r + \partial y^t \end{bmatrix} = \begin{bmatrix} x \cdot (k_1 \cdot r^2 + k_2 \cdot r^4) + 2p_1 \cdot xy + p_2(r^2 + 2x^2) \\ y \cdot (k_1 \cdot r^2 + k_2 \cdot r^4) + p_1(r^2 + 2y^2) + 2p_2 \cdot xy \end{bmatrix} \quad (7)$$



Ilustrare a efectului distorsiunii lentilelor. Imaginile prezentate au fost obținute făcând diferența între imaginea distorsionată și imaginea corectată. Diferențele apar cu tonuri de gri și sunt mai accentuate în zonele cu muchii mai depărtate de centrul imaginii. În zonele centrale diferențele sunt aproape nule.



Imagine diferenta = abs (I-I2)

Obiectiv Schneider-Kreuznach $f = 4.5 \text{ mm}$

$k1 = -0.22267$

$k2 = 0.05694$

$p1 = -0.00009$

$p2 = 0.00036$

Algoritmul de corecție al distorsiunilor

Ideea care stă la baza algoritmului de corecție este că, între pixelii celor două imagini (cei distorsionați $(x', y') = (x + \alpha x, y + \alpha y)$ și cei ne-distorsionați/corectați (x, y)) există o corespondență biunivocă, astfel că pentru fiecare locație de coordonate întregi (x, y) din imaginea corectată (exprimată în sistemul de coordonate al camerei) îi va corespunde o valoare de intensitate de la locația (x', y') calculată cu formulele (7). Deoarece coordonatele (x', y') sunt valori flotante se va lua valoarea de intensitate interpolată de la această locație din imaginea achiziționată (distorsionată).

Algoritmul de corecție (inverse warping):

Pentru fiecare pixel de la locația “întreaga” (u, v) [pixeli] din imaginea corectată **D**:


- Se calculează coordonatele (x, y) în sistemul de coordonate al camerei:
$$\begin{cases} x = \frac{u - u_0}{f_x} \\ y = \frac{v - v_0}{f_y} \end{cases} \quad (8)$$
- Se calculează coordonatele corespunzătoare din imaginea distorsionată $(x', y') = (x + \alpha x, y + \alpha y)$ cu ajutorul (7)
- Pentru aceste coordonate distorsionate (x', y') se calculează coordonatele corespunzătoare în pixeli:

$$\begin{cases} u' = u_0 + x' \cdot f_x \\ v' = v_0 + y' \cdot f_y \end{cases} \quad (9)$$

- Se atribuie valorii intensității de la locația (u, v) din imaginea corectată **D** valoarea interpolată din imaginea distorsionată **S** de la locația (u', v') :

$$D(u, v) = S(u', v') \quad (10)$$

Metoda de interpolare folosită este cea bi-liniară care dă rezultate calitativ similare cu metoda de interpolare bi-cubică dar cu un efort computațional mai scăzut.



$$\begin{aligned} u_0 &= \text{int}(u'); \\ v_0 &= \text{int}(v'); \\ u_1 &= u_0 + 1; \\ v_1 &= v_0 + 1; \\ I_0 &= S(u_0, v_0) * (u_1 - u') \\ &\quad + S(u_0, v_1) * (u' - u_0); \\ I_1 &= S(u_1, v_0) * (u_1 - u') \\ &\quad + S(u_1, v_1) * (u' - u_0); \\ D(u, v) &= I_0 * (v_1 - v') + I_1 * (v' - v_0); \end{aligned}$$

Ilustrarea procesului de interpolare liniara a intensităților din imagine.

Parametrii extrinseci

Poziția și orientarea sistemului de coordonate 3-D asociat camerei relativa la sistemul de coordonate asociat lumii

Necesari pentru a transforma coordonatele unui punct din sistemul de coordonate al lumii in sistemul de coordonate al camerei și invers)


Vectorul de translație $\mathbf{T} = [T_x, T_y, T_z]^T$;

Vectorul de rotație $\mathbf{r} = [R_x, R_y, R_z]^T$ sau *matricea de rotație* echivalentă $\mathbf{R} = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix}$

În sistemele stereo cu mai multe camere, parametrii extrinseci ne permit de asemenea să exprimăm și relația spațială dintre aceste camere.

Maparea directă (din sistemul lumii în sistemul camerei)

$\mathbf{XX}_W = [X_W, Y_W, Z_W]^T$ (sistemul de coordonate al lumii - WRF) $\Rightarrow \mathbf{XX}_C = [X_C, Y_C, Z_C]^T$ (sistemul de coordonate al camerei – CRF)



$$\mathbf{XX}_C = \mathbf{R}_{WC} \cdot \mathbf{XX}_W + \mathbf{T}_{WC} \quad (5)$$


unde: $\mathbf{T}_{WC} = [T_x \ T_y \ T_z]^T$ – vectorul de translație din sistemul lumii în sistemul camerei

(poziția centrului sistemului de coordonate al lumii în sistemul de coordonate al camerei);

$\mathbf{R}_{WC}$ – matricea de rotație din sistemul lumii în sistemul camerei;

Maparea inversa (din sistemul camerei în sistemul lumii)

$\mathbf{XX}_C = [X_C, Y_C, Z_C]^T$ (sistemul de coordonate al camerei – CRF) $\Rightarrow \mathbf{XX}_W = [X_W, Y_W, Z_W]^T$ (sistemul de coordonate al lumii - WRF)



$$\mathbf{XX}_W = \mathbf{R}_{WC}^{-1} \cdot (\mathbf{XX}_C - \mathbf{T}_{WC}) \quad (6)$$

Matricea de rotație este ortogonală [Trucco1998]: $\mathbf{R} \cdot \mathbf{R}^T = \mathbf{R}^T \cdot \mathbf{R} = 1 \Rightarrow \mathbf{R}^T = \mathbf{R}^{-1}$

$$\mathbf{XX}_W = \mathbf{R}_{WC}^T \cdot (\mathbf{XX}_C - \mathbf{T}_{WC}) = \mathbf{R}_{CW} \mathbf{XX}_C + \mathbf{T}_{CW} \quad (7)$$

unde: $\mathbf{T}_{CW} = [T_X \ T_Y \ T_Z]^T$ – vectorul de translație din sistemul camerei în sistemul lumii: $\mathbf{T}_{CW} = -\mathbf{R}_{WC}^T \mathbf{T}_{WC}$

(poziția centrului sistemului de coordonate al camerei în sistemul de coordonate al lumii);

$\mathbf{R}_{CW}$ – matricea de rotație din sistemul camerei în sistemul lumii: $\mathbf{R}_{CW} = \mathbf{R}_{WC}^T$

Semnificatia elementelor matricii de rotatie

$$\mathbf{R}_{WC} = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix} = \begin{bmatrix} \mathbf{n}^{XW} & \mathbf{n}^{YW} & \mathbf{n}^{ZW} \end{bmatrix} = \begin{bmatrix} n_X^{XW} & n_X^{YW} & n_X^{ZW} \\ n_Y^{XW} & n_Y^{YW} & n_Y^{ZW} \\ n_Z^{XW} & n_Z^{YW} & n_Z^{ZW} \end{bmatrix} \quad (8)$$

where:

$\mathbf{n}^{XW} = \begin{bmatrix} n_X^{XW} & n_Y^{XW} & n_Z^{XW} \end{bmatrix}^T$ – vectorul normal corespunzator axei $\mathbf{OX}_W$ a in sistemul de coordonate al camerei

$\mathbf{n}^{YW} = \begin{bmatrix} n_X^{YW} & n_Y^{YW} & n_Z^{YW} \end{bmatrix}^T$ – vectorul normal corespunzator axei $\mathbf{OY}_W$ a in sistemul de coordonate al camerei

$\mathbf{n}^{ZW} = \begin{bmatrix} n_X^{ZW} & n_Y^{ZW} & n_Z^{ZW} \end{bmatrix}^T$ – vectorul normal corespunzator axei $\mathbf{OZ}_W$ in sistemul de coordonate al camerei

$$\mathbf{R}_{CW} = \mathbf{R}_{WC}^T = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix} = \begin{bmatrix} \mathbf{n}^{XC} & \mathbf{n}^{YC} & \mathbf{n}^{ZC} \end{bmatrix} = \begin{bmatrix} n_X^{XC} & n_X^{YC} & n_X^{ZC} \\ n_Y^{XC} & n_Y^{YC} & n_Y^{ZC} \\ n_Z^{XC} & n_Z^{YC} & n_Z^{ZC} \end{bmatrix} \quad (9)$$

where:

$\mathbf{n}^{XC} = \begin{bmatrix} n_X^{XC} & n_Y^{XC} & n_Z^{XC} \end{bmatrix}^T$ – vectorul normal corespunzator axei $\mathbf{OX}_C$ a in sistemul de coordonate al lumii

$\mathbf{n}^{YC} = \begin{bmatrix} n_X^{YC} & n_Y^{YC} & n_Z^{YC} \end{bmatrix}^T$ – vectorul normal corespunzator axei $\mathbf{OY}_C$ a in sistemul de coordonate al lumii

$\mathbf{n}^{ZC} = \begin{bmatrix} n_X^{ZC} & n_Y^{ZC} & n_Z^{ZC} \end{bmatrix}^T$ – vectorul normal corespunzator axei $\mathbf{OZ}_C$ in sistemul de coordonate al lumii

Mapare directă completa (3D world) $\Rightarrow$ (2D image): proiectie

Matricea de proiectie:

$$\mathbf{P} = \mathbf{A} \cdot [\mathbf{R}_{WC} \mid \mathbf{T}_{WC}] \quad (10)$$

Punct 3D din lume de coordonate $[X_W, Y_W, Z_W]$

$$s \cdot \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} x_S \\ y_S \\ z_S \end{bmatrix} = \mathbf{P} \cdot \begin{bmatrix} X_W \\ Y_W \\ Z_W \\ 1 \end{bmatrix} \quad (11)$$

Obținerea coordonatelor imagine 2D:

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} x_S / z_S \\ y_S / z_S \end{bmatrix} \quad (12)$$

Bibliografie

E. Trucco, A. Verri, *Introductory Techniques for 3-D Computer Vision*, Prentice Hall, 1998.

S. Nedevschi, R. Dănescu, F. Oniga, T. Marița, [Tehnici de viziune artificială aplicate în conducerea automată a autovehiculelor](#), Editura U.T. Press, Cluj-Napoca, 2012, pp. 7-17, pp. 45-47.


Proprietăți geometrice simple ale obiectelor din imagini binare (alb/negru)

Imagine binara?


2 nuanțe:

alb ("0") – pixelii de fond


negru ("1") – pixelii aparținând obiectelor




Grayscale (monocromă)



Histograma





Alb/negru (binara)



Negativ

⇒ Binarizare

Imagini care nu se pot segmenta prin binarizare:



1. Proprietăți geometrice simple

Simplificare: imagine cu un singur obiect:



Notății:

$$b(x, y) = \begin{cases} 1 & \text{pixel_obiect} \\ 0 & \text{pixel_fond} \end{cases} \Rightarrow \text{culoarea/intensitatea pixelului de la locatia (x,y)}$$

Momente spațiale: $m_{ji} = \sum_{x,y} b(x, y) \cdot x^j \cdot y^i$

Momente centrate (invariante la translație): $mu_{ji} = \sum_{x,y} b(x, y) \cdot (x - \bar{x})^j \cdot (y - \bar{y})^i$

Momente centrate și normalizate (invariante la scalare): $nu_{ji} = \frac{mu_{ji}}{m_{00}^{\frac{j+i}{2}+1}}$

https://docs.opencv.org/2.4/modules/imgproc/doc/structural_analysis_and_shape_descriptors.html?highlight=moments#moments

https://en.wikipedia.org/wiki/Image_moment

1.1 Aria obiectului

$$A = \iint_I b(x, y) dx dy$$

sau pentru cazul discret (nr. pixelilor obiect):

$$A = \sum_{y=1}^n \sum_{x=1}^m b(x, y) = m_{00} \quad \text{unde: } y = [1 \dots n] \text{ și } x = [1 \dots m]$$

1.2 Poziția / centrul de masa

Centrul de masa := acel punct al obiectului în care poate fi concentrata întreaga masa a obiectului fără a schimba momentul de ordinul I al obiectului pe direcția oricărei axe

Momentul de ordin 1 pe direcția axei x:

$$\bar{x} \cdot \iint_I b(x, y) dx dy = \iint_I x b(x, y) dx dy \Leftrightarrow \bar{x} \cdot \sum_{y=1}^n \sum_{x=1}^m b(x, y) = \sum_{y=1}^n \sum_{x=1}^m x b(x, y) \Leftrightarrow \bar{x} \cdot m_{00} = m_{10}$$

Momentul de ordin 1 pe direcția axei x:


$$\bar{y} \cdot \iint_I b(x, y) dx dy = \iint_I y b(x, y) dx dy \quad \Leftrightarrow \quad \bar{y} \cdot \sum_{y=1}^n \sum_{x=1}^m b(x, y) = \sum_{y=1}^n \sum_{x=1}^m y b(x, y) \quad \Leftrightarrow \quad \bar{y} \cdot m_{00} = m_{01}$$

unde $(\bar{x}, \bar{y})$ sunt coordonatele centrului de masa

$$\bar{x} = \frac{\sum_{y=1}^n \sum_{x=1}^m x b(x, y)}{A} = \frac{m_{10}}{m_{00}}, \quad \bar{y} = \frac{\sum_{y=1}^n \sum_{x=1}^m y b(x, y)}{A} = \frac{m_{01}}{m_{00}}$$

1.3 Orientarea

(direcția de alungire / axa de inerție minimă / axa cu cel mai mic moment de ordin 2)




Momentul de ordin 2:

$$E = \iint_I r^2 b(x, y) dx dy \quad (1)$$

Unde:

r este distanța de la punctul (x, y) la dreapta căutată (axa de inerție minimă).



Ecuția dreptei:

$$x \sin \theta - y \cos \theta + \rho = 0 \quad (2)$$

Soluția: determinarea dreptei pt. care momentul de ordin 2 este minim: $E'(\rho, \theta) = 0$

Pentru un punct (x, y) al obiectului, distanța r dintre acest punct și dreapta va fi:

$$r^2 = (x \sin \theta - y \cos \theta + \rho)^2 \quad (3)$$

Înlocuind (3) în (1):

$$E = \iint_I (x \sin \theta - y \cos \theta + \rho)^2 b(x, y) \, dx \, dy \quad (4)$$

Derivând E după ρ și egalând cu 0 obținem:

$$\begin{aligned} E'_\rho &= \iint_I 2(x \sin\theta - y \cos\theta + \rho)b(x,y)dxdy = 2\sin\theta \iint_I xb(x,y)dxdy - 2\cos\theta \iint_I yb(x,y)dxdy + 2\rho \iint_I b(x,y)dxdy = \\ &= 2A(\bar{x}\sin\theta - \bar{y}\cos\theta + \rho) = 0 \end{aligned} \quad (5)$$

unde: $(\bar{x}, \bar{y})$ este centrul de masă al obiectului.

$\Rightarrow$ Axa de inerție minimă trece prin centrul de greutate !

Notății (translație a originii sistemului de coordonate al imaginii în centrul de masă):

$$x' = x - \bar{x} \quad \text{și} \quad y' = y - \bar{y}$$

$\Rightarrow$

$$x \sin\theta - y \cos\theta + \rho = x' \sin\theta - y' \cos\theta \quad (6)$$

Înlocuind (6) în (4):

$$E = a \sin^2\theta - b \sin\theta \cos\theta + c \cos^2\theta$$

unde a, b, c sunt momentele (centrate) de ordin 2:

$$a = \iint_{I'} (x')^2 b(x,y) dx' dy' = \mu_{20}$$

$$b = 2 \iint_{I'} (x' y') b(x,y) dx' dy' = 2\mu_{11}$$

$$c = \iint_{I'} (y')^2 b(x,y) dx' dy' = \mu_{02}$$

Rescriem E in forma:

$$E = \frac{1}{2}(a+c) - \frac{1}{2}(a-c)\cos 2\theta - \frac{1}{2}b\sin 2\theta \quad (7)$$

Derivând E după θ si egalând cu 0 obținem:

$$E'_\theta = (a-c)\sin 2\theta - b\cos 2\theta = 0$$

$$\tan 2\theta = \frac{b}{a-c}$$

Cazurile $b=0$ si $a=c$ corespund dreptelor orizontale respectiv verticale si trebuiesc tratate special

$$\sin 2\theta = \pm \frac{b}{\sqrt{b^2 + (a-c)^2}} \quad \text{si} \quad \cos 2\theta = \pm \frac{a-c}{\sqrt{b^2 + (a-c)^2}}$$

soluția pozitivă $\Rightarrow$ E-minim

soluția negativă $\Rightarrow$ E-maxim

$$\text{Factor} _ \text{forma} = \frac{L_{E \max}}{L_{E \min}} \quad (0 - \text{linie}, 1 - \text{cerc})$$

Alte proprietati geometrice simple

Neregularitatea conturului („compactness”): $T = 4\pi \left(\frac{A}{P^2} \right)$ (val maxima = 1 / cerc)

Momente Hu (proprietati invariante: translatie, scalare, rotatie):

$$hu[0] = \eta_{20} + \eta_{02}$$

$$hu[1] = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2$$

$$hu[2] = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2$$

$$hu[3] = (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2$$

$$hu[4] = (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2]$$

$$hu[5] = (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03})$$

$$hu[6] = (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] - (\eta_{30} - 3\eta_{12})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2]$$

unde: $\eta \equiv nu$ (momente centrate si normalizate)

2. Proiecțiile

Proiecția unui obiect pe o dreaptă cu direcția θ :

$$p_{\theta}(t) = \int_L b(t \cdot \cos \theta - s \cdot \sin \theta, t \cdot \sin \theta + s \cdot \cos \theta) ds$$

2.1 Proiecția verticală ($\theta = 0$)

$$v(x) = \int_L b(x, y) dy$$

2.2 Proiecția orizontală ($\theta = \pi/2$)

$$h(y) = \int_L b(x, y) dx$$

2.3 Aria


$$A = \iint_I b(x, y) dx dy \quad ; \quad A = \int v(x) dx = \int h(y) dy$$

2.4 Coordonatele centrului de masa

$$\bar{x} A = \iint_I x b(x, y) dx dy = \int x v(x) dx$$

$$\bar{y} A = \iint_I y b(x, y) dx dy = \int y h(y) dy$$

(momentele de ordin 1 ale proiecțiilor sunt egale cu cele ale imaginii originale)




2.5. Aplicații ale proiecțiilor

Problema 1: Segmentați (puneți în evidență / izolați) fiecare litera dintr-un text (tiparit).


ABTH	HGH	AJJA
ABSN	ANS	ALOPL
POS	WOSKD	PLD

Problema 2:


Detectați centrul formei în forma de ,X' de mai jos:



Recunoașterea de caractere $\Rightarrow$ detecția caracterelor (liniilor și coloanelor)



Recunoaștere de forme / detecție de proprietăți geometrice ale unor forme



a. Zona dreptunghiulară care mărginește o forma de tip "X" b. Suma intensității pixelilor de-a lungul coloanelor zonei de interes; c. Suma intensității pixelilor de-a lungul rândurilor zonei de interes.

3. Codificare Run-Length (compresie)

1	1	1	0	0	0	1	1	0	0	0	1	1	1	1	0	1	1	0	1	1	1
0	0	0	0	1	1	1	1	1	1	1	1	1	1	1	1	1	0	1	1	1	1
1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	1	1	1	1

Var. 1

Poz. start și lungimea secv. De “1”:

(1,3) (7,2) (12,4) (17,2) (20,3)
 (5,13) (19,4)
 (1,3) (17,6)

Var. 2

Lungimea secv. de 0 și 1 :

0,3,3,2,4,1,2,1,3
 4,13,1,4 i
 0,3,13,6

k

Folosim convențiile:

- r_{ik} este secvența k a liniei i
- prima secvență din fiecare linie este o secvență de 0 $\Rightarrow$ secvențele pare corespund la “1” ($k=2j$).
- Avem m_i secvențe pe linia i

Calculul proprietarilor geometrice din codificarea run-length


Aria:

$$A = \sum_{i=1}^n \sum_{k=1}^{m_i/2} r_{i,2k}$$

Centrul de masa:

Se calculează mai întâi proiecțiile orizontale

$$h_i = \sum_{k=1}^{m_i/2} r_{i,2k}$$



Proiecțiile orizontale calculate din codificarea RLE

Poziția verticală $\bar{i}$ a centrului de masa:

$$A \cdot \bar{i} = \sum_{i=1}^n i h_i$$



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

(An3, semestrul 2)



**Curs 4: Etichetarea obiectelor. Detectia conturului
obiectelor**



Definitii

1. Vecini

- Doi pixeli sunt intr-o relatie de vecinatate de tip N4 daca au o frontiera comuna
- Doi pixeli sunt intr-o relatie de vecinatate de tip N8 daca au cel putin un colt comun




2. Cale (Path)

$$\text{Path } (p[i_0, j_0] \Rightarrow p[i_n, j_n]) := \{ [i_0, j_0], [i_1, j_1], \dots, [i_n, j_n] \\ | [i_k, j_k] N_{4/8} [i_{k+1}, j_{k+1}] \forall k = 0 \dots n-1 \}$$


N4 $\Rightarrow$ 4-path

N8 $\Rightarrow$ 8-path

4-path



8-path





Definitii

3. Obiect (Foreground)

$$S := \{ p[i,j] \mid p[i,j] = 1 \}$$

4. Conectivitate (Connectivity)

$$p_S \leftrightarrow q_S \text{ (connected) if } \exists \text{ Path } (p \Rightarrow q) \subset S.$$

5. Componente conexe (Connected components) = OBIECTE

$$\{p_i \in S, i = 1 \dots n \mid p_k \leftrightarrow p_j, \forall (p_k, p_j) \in S, k, j = 1 \dots n\}$$

6. Fundal (Background) := setul tuturor componentelor conexe ale $C(S)$ care au elemente (puncte) pe marginea imaginii. Toate celelalte componente conexe din $C(S)$ se numesc goluri.

7. Frontiera/Margine (Boundary)

$$\text{Boundary } (S) := S' = \{ p \in S \mid \exists q \in N_{4/8}(p), q \in C(S) \}$$

$C(S)$ – complement of S

8. Interior

$$\text{Interior } (S) = S - S'$$



Etichetarea componentelor conexe

Componenta conexa (obiect)

Setul maximal de puncte conexe:


$$\{p_i \in S, i = 1 \dots n \mid p_k \leftrightarrow p_j, \forall (p_k, p_j) \in S, k, j = 1 \dots n\}$$

O modalitate de a eticheta obiectele dintr-o imagine digitala binara este de a alege un punct $b_{ij} = 1$ si a asigna o eticheta acestui punct si vecinilor acestuia. Mai departe se vor eticheta toti vecinii vecinilor

- Cand procedura recursiva/iterativa se termina, se va obtine o componenta conexa etichetata complet si putem continua alegand alt punct de start (neetichetat inca)
- Pentru a gasi un nou punct de start, se va parcurge imaginea in mod sistematic , incepand o procedura de etichetare de fiecare data cand se gaseste un punct $b_{ij} = 1$.



$\Rightarrow$
Etichetare
(Labeling)





Etichetare secventiala

Algorithmul Iterativ (Haralick 1981)

- Nu necesita spatiu suplimentar de memorie pentru a genera imaginea etichetata din imaginea binara.
- Utila in sisteme cu memorie limitata.

1. Pas de initializare

2. repeat

 propagare top-down & left-right a etichetelor

 propagare bottom-up & right-left a etichetelor

until “nu mai apare nici o schimbare”

procedure Iterate;

// Initializare a fiecarui pixel de “1” cu o eticheta unica

for L:=1 to NLINES **do**

for P:=1 to NCOLUMNS **do**

if I(L,P) =1

then LABEL(L,P):=NEWLABEL()

else LABEL(L,P):=0

end for

end for;

LABEL – matrice
de etichete



Etichetare secventiala

“**procedure** Iterate – pag. 2”

“Iteratii succesive: top-down si bottom-up”

repeat

CHANGE:=false;

// Iteratie top-down

for L:=1 to NLINES **do**

for P:=1 to NCOLUMNS **do**

if LABEL(L,P)<>0 **then**

begin

 M:=MIN(LABELS(NEIGHBORS(L,P)U(L,P)));

if M <> LABEL(L,P)


then CHANGE:=true;

 LABEL(L,P):=M

end

end for

end for;





Etichetare secventiala

“procedure Iterate – pag. 3”

// Iteratie bottom-up”

for L:= NLINES to 1 by -1 **do**

for P:= NCOLUMNS to 1 by -1 **do**

if LABEL(L,P)<>0 **then**

begin

 M:=MIN(LABELS(NEIGHBORS(L,P)U(L,P)));

if M<> LABEL(L,P)

then CHANGE:=true;

 LABEL(L,P):=M

end

end for

end for;

until CHANGE:=false

end Iterate





Etichetare secventiala

Exemplu (N4)

	1	1		1	1	
	1	1		1	1	
	1	1	1	1	1	

1. Imagine initiala

	1	2		3	4	
	5	6		7	8	
	9	10	11	12	13	

2. Initializare

	1	1		3	3	
	1	1		3	3	
	1	1	1	1	1	

3. Propagarea etichetelor:
top-down & left-right

	1	1		1	1	
	1	1		1	1	
	1	1	1	1	1	

4. Propagarea etichetelor:
bottom-up & right-left



Algoritmul clasic (cu clase de echivalenta)

- Bazat pe algoritmul clasic de gasire a componentelor conexe din grafuri.
- Necesita doar **2 iteratii** peste imagine, dar are nevoie de o tabela (mare) pentru inregistrarea **echivalentelor**.

1. **Primul pas:** propagarea etichetelor (similar cu algoritmul precedent)

- De fiecare data cand se intalneste situatia in care doua etichete diferite se pot propaga la acelasi pixel, se va propaga eticheta cea mai mica si echivalenta gasita se introduce intr-o tabela de echivalente (ex. (1,2) → EqTable).
- Fiecare intrare din tabela de echivalenta consta intr-o pereche ordonata, valorile continute in fiecare pereche fiind valorile etichetelor gasite echivalente
- Dupa acest pas se gasesc clasele de echivalenta.
- Fiecarei clase de echivalenta i se asigneaza o eticheta unica (valoarea minima sau cea mai veche din clasa).

						1	1
						1	1
						1	1
						1	1
						1	1
						1	1
						1	1
						1	1

2. **Al doilea pas:** se parcurge imaginea si se asigneaza fiecarui pixel valoarea etichetei corespunzatoare clasei de echivalenta din care face parte).



Algoritmul Clasic

Exemplu (N4)

1					1	1
		1	1			1
		1				1
		1				1
1	1	1				1
	1	1		1		1
	1	1	1	1		1
				1	1	1

1. Imagine initiala

1					2	2
		3	3			2
		3				2
		3				2
4	4	3				2
	4	3		5		2
	4	3	3	3		2
				3	3	2

2. Imagine etichetata dupa prima parcurgere
Top down (pas 1)

EQTABLE:

(3, 4), (3, 5), (2, 3) ...

EQCLASSES:

1: {4, 3, 5, 2}

2: {6, 8, 9, ...}

....

n: {...}

EQLABEL:

1: 2 1:1

2: 6 sau 2:2

...

n: x n:n



Algoritmul Clasic

procedure Classical

“Initializare tabela de echivalente globale” si matricea de etichete

EQTABLE:=CREATE(); LABEL:=CREATE();

“Top-down pass 1”

for L:= 1 to NLINES **do**

“Initialize all labels on line L to zero”

for P:= 1 to NCOLUMNS **do**

LABEL(L,P):=0

end for

“Process the line”

for P:=1 to NCOLUMNS **do**

if I(L,P):= 1 **then**
begin

V:= NEIGHBORS((L,P));

if ISEMPY(V)

then M:=NEWLABEL()

else M:= MIN(LABELS(V));

LABEL(L,P):=M;

for X in LABELS(V) and X<>M

ADD(X, M, EQTABLE)

end for;

end

end for

end for;

LABEL – matrice (“image”) de etichete




IMAGE PROCESSING



Algoritmul Clasic

“Find equivalence classes”

EQCLASSES:=**Resolve**(EQTABLE);

for E in EQCLASSES

 EQLABEL(E):= min(LABELS(E))

end for;

“Top-down pass 2”

for L:= 1 to NLINES **do**

for P:= 1 to NCOLUMNS **do**

if I(L,P) = 1

then LABEL(L,P):=EQLABEL(CLASS(LABEL(L,P)))

end for

end for

end Classical

- **Resolve()** - algoritm pt. gasirea componentelor conexe ale grafului definit de setul de echivalente (**EQTABLE**) definit la pasul 1.
- Problema principala a acestui algoritm: pentru imagini mari cu multe regiuni, tabela de echivalente poate deveni foarte mare



Algoritmul Clasic

Procedura *Resolve()*

Pentru a modela echivalența etichetelor putem folosi un graf neorientat în care **nodurile sunt etichetele** iar **arcele sunt relațiile binare de echivalență** stabilite în pasul anterior (o intrare în tabela EQTABLE) $\Rightarrow$ **clasele de echivalență sunt subgrafurile conexe** ale acestui graf.

Subgraf conex $\Rightarrow$ căutare în lățime (Breadth First Search, BFS), pornind dintr-un prim nod oarecare al subgrafului:

- se pun toți vecinii primului nod într-o listă și se marchează ca fiind luați în considerare
- pentru fiecare nod din lista respectivă, acesta este extras din listă, și i se adaugă toți vecinii (neconsiderați încă) în listă și se marchează ca fiind luați în considerare.
- procesul se repetă pentru fiecare nod adăugat în listă, până când lista devine goală
- toate nodurile trecute prin această listă vor fi etichetate cu aceeași etichetă, care va fi noua etichetă asociată acestei clase de etichete echivalente.

În continuare se caută un alt nod care nu a fost considerat, și pornind de la acesta se va căuta o nouă clasă de echivalență. Procesul se continuă până când sunt considerate toate nodurile grafului. Fiecare nod singular reprezintă câte o clasă de echivalență cu un singur element.



Rezolvarea claselor de echivalenta

EQCLASSES:=**Resolve**(EQTABLE);

Ex. EQTABLE:


x	y
3	4
3	5
2	3
6	8
6	9
7	8
..	..

Vom utiliza algoritmul BFS, bazat pe o coada Q

- Definim multimea vecinatate a unei etichete L

Neighborhood (L) = { M | $\exists k$ | EQTABLE(k).x == L si EQTABLE(k).y == M,
sau EQTABLE(k).x == M si EQTABLE(k).y == L }

- Q – o structura de date de tip coada (lista FIFO)
 - Q.empty() - returneaza **true** daca coada este goala (top = bottom)
 - Q.enqueue(p) - plaseaza un nod (eticheta) in coada (top++)
 - p = Q.dequeue() - scoate un nod (eticheta) din coada (bottom ++)





Rezolvarea claselor de echivalenta

Procedure Resolve()

For L = 1 to MAX_LABELS EQCLASSES(L) = 0 **end for**

For L = 1 to MAX_LABELS

if (EQCLASSES(L) == 0)

 EQCLASSES (L) = NEW_EQUIVALENCE_CLASS()

 Q.enqueue(L)

while (**not** Q.empty())

 M = Q.dequeue()

For all N in Neighborhood(M)

if (EQCLASSES(N) == 0)

 EQCLASSES(N) = EQCLASSES(M)

 Q.enqueue(N)

End if

End for

End while

End for

Return EQCLASSES




Contour Tracing (detectie contur)

Contur:


$$\text{Contour (R)} = \{ p \in R \mid \exists q \in N_{4/8}(p), q \in C(R) \}$$

(*chain-code / direction codes*): c


(operatiile numerice asupra lui c se presupun a fi modulo 4 sau 8)




(a)




(b)




(c)



(d)




(e)



(f)




Contour Tracing (detectie contur)



Algoritm trasare contur exterior:

1. Cauta in imagine (top-down si left-right) pana cand gaseste un pixel de start P_0 . Se defineste o variabila dir care stocheaza valoarea directiei ultimei mutari (miscari) de-a lungul conturului, de la pixelul precedent la cel curent. Valorile initiale se asigneaza astfel:
 - $dir = 0$ pt. N4
 - $dir = 7$ pt. N8

2. Se cauta urmatorul punct de contur intr-o vecinatate de 3×3 in jurul pixelului curent, secvential ($dir++$), in sens anti-orarar, incepand cu directia
 - $(dir + 3) \bmod 4$
 - $(dir + 7) \bmod 8$ if dir este par
 - $(dir + 6) \bmod 8$ if dir este impar





Primul pixel de "1" gasit este noul element de contur curent P_n . In acelasi timp se actualizeaza valoarea dir .

3. Daca elementul de contur curent P_n este egal cu elemntul P_1 si daca elementul P_{n-1} este egal cu P_0 , STOP. Altfel repeta pasul 2.
4. Conturul detectat este reprezentat de multimea: $P_0 \dots P_{n-2}$.



Exemplu – reprezentarea conturului (N8)



$c_i \in \{0, 1, \dots, 7\}$ - cod de directie

Var.1 – lista de puncte:

$$L = \{ P_0(x_0, y_0), P_1(x_1, y_1), \dots, P_{n-2}(x_{n-2}, y_{n-2}) \}$$

Var.2 – coduri inlantuite:

$$P_0(x_0, y_0), c = \{c_0, c_1, \dots, c_{n-2}\},$$

Var.3 – derivata codului inlantuit (**invarianta la rotatie**)

$$P_0(x_0, y_0), cd = \{cd_0, cd_1, \dots, cd_{n-2}\},$$

$$\text{unde: } cd_i = (c_i - c_{i-1}) \bmod 8, \quad cd_0 = c_0 \bmod 8$$



Aproximarea conturului prin linii poligonale

Scop:

Aproximarea curbei $C: f(x,y)=0$ cu o linie poligonala avand un numar relativ mic de linii (varfuri) care aproximeaza cel mai bine curba C



- Orice algoritm de aproximare poligonala necesita ca punctele (datele) sa fie divizate in grupuri, fiecare dintre acestea fiind approximate de cate o latura a poligonului
- Prima simplificare a problemei de fitting este de a duce o linie intre capetele fiecarui grup In loc sa cautam solutia optimala.
- Daca eroarea de aproximare este prea mare , grupul se poate sparge in sub-grupuri pana cand eroarea de aproximare devine acceptabila.
- Fie Q un contur alcatuit din punctele $P_i (x_i, y_i)$ unde $i=1, 2, \dots, n$, si ε eroarea maxima.



Aproximarea conturului prin linii poligonale

Procedure POLIGONAL_APROX(Q)

begin

A:=Create_List();

B:=Create_List();

i=Index_of_first_point(Q);

j=Index_of_the_most_far_point(Q);

Insert(j,A); Insert(j,B); // B = (P_j)

Insert(i,A); // A = (P_j, P_i)

while((A!=NULL)

{

Fie *k* și *l* indecșii ultimelor elemente din listele *A* și *B*;

Fie *P_kP_l* segmentul generat de cele două puncte;

Fie *m* indexul celui mai îndepărtat punct de segmentul *P_kP_l*, dintre punctele de contur ce încep din *P_k* și se termină în *P_l*, conturul fiind parcurs în sens opus acelor de ceasornic.


if((d=Distance(P_m, P_kP_l))> ε)

then Insert(m, A)

else { Delete(k, A)
Insert(k, B); }

}


end



$$\text{distance}(P_1, P_2, (x_0, y_0)) = \frac{|(y_2 - y_1)x_0 - (x_2 - x_1)y_0 + x_2y_1 - y_2x_1|}{\sqrt{(y_2 - y_1)^2 + (x_2 - x_1)^2}}$$



Aproximarea conturului prin linii poligonale - exemplu



A	B
2	2
1	
3	
4	
2	2
1	4
3	
2	2
1	4
	3
2	2
	4
	3
	1
2	2
5	4
	3
	1

A	B
2	2
5	4
7	3
	1
2	2
5	4
	3
	1
	7
2	2
	4
	3
	1
	7
	5
2	2
6	4
	3
	1
	7
	5

A	B
2	2
	4
	3
	1
	7
	5
	6
	2
	2
	4
	3
	1
	7
	5
	6
	2


PRELUCRARI PE IMAGINI BINARE (ALB/NEGRU)

Imagine binara?

2 nuante:

alb ("0") – pixelii de fond ($I(x,y) = 255$ pt. imagini indexate cu 8 biti/pixel)

negru ("1") – pixelii apartinand obiectelor ($I(x,y) = 0$ pt. imagini indexate cu 8 biti/pixel)




Notatii:

$$b(x, y) = \begin{cases} 1 & \text{pixel_obiect} \\ 0 & \text{pixel_fond} \end{cases} \Rightarrow \text{eticheta pixelului de la locatia (x,y)}$$



Grayscale



Alb/negru (binara)

Transformarea grayscale $\Rightarrow$ alb/negru: **binarizare (thresholding)**

$$Dst(x, y) = \begin{cases} 0 & (\text{black} = '1') \quad , \quad \text{if} \quad Src(x, y) < threshold \\ 255 & (\text{white} = '0') \quad , \quad \text{if} \quad Src(x, y) \geq threshold \end{cases}$$

OPERATII MORFOLOGICE

Morfologie := [moprphos = forma] forma si structura organismelor vii

Morfologie matematica $\Rightarrow$ unelte pentru modificarea formei sau extragere de componente, reprezentarea si descrierea formei unei regiuni / obiect (contur, skeleton).

Teorie mulțimilor (set-urilor) $\Rightarrow$ Limbajul folosit in morfologia matematica

Fie **A** o **mulțime** din Z^2 . Dacă $a = (a_1, a_2)$ este un element din **A**:

$$a \in A.$$

Similar, daca **a nu** este un element din **A**:

$$a \notin A.$$

Mulțimea fără nici un element: $\emptyset$.

Notatie: $\{ \dots \}$

Elementele mulțimilor pe care le consideram: pixeli $b(x,y)$ ai obiectelor imagini binare

Relații / operații pe mulțimi

1. Incluziunea

$$A \subseteq B$$

2. Reuniunea

$$C = A \cup B$$

3. Intersecția

$$D = A \cap B$$

4. Mulțimi disjuncte (mutual exclusive)

$$A \cap B = \emptyset.$$

5. Complementul

$$A^C = \{w \mid w \notin A\}$$

6. Diferența


$$A - B = \{w \mid w \in A, w \notin B\} = A \cap B^C$$

7. Reflexia (flip orizontal + vertical)

$$\hat{B} = \{w \mid w = -b, \text{ for } b \in B\}$$

8. Translația (setului A cu $z = (z_1, z_2)$)


$$(A)_z = \{c \mid c = a + z, \text{ for } a \in A\}$$




Operații logice / aritmetice aplicate pe imagini binare

- **Unare**: imagine **op** operand_scalar
- **Binare**: imagine1 **op** imagine2
- Realizate la nivel de pixel


Operații logice: AND, OR, and NOT (COMPLEMENT) + orice alte combinații




A



B




A and B




A or B



not (A) = A^C



A xor B



not(A) and B = B-A

DILATAREA SI EROZIUNEA

Dilatarea si eroziunea - cele doua primitive de baza ale operațiilor morfologice!

$$A, B \subset \mathbb{Z}^2$$




DILATAREA

Dilatarea A cu B

$$A \oplus B = \{z | (\hat{B})_z \cap A \neq \emptyset\} \quad \text{sau} \quad A \oplus B = \{z | [(\hat{B})_z \cap A] \subseteq A\}$$

B – element structural

:




Alta definiție pt. dilatare

$a=(a_1, a_2, \dots, a_N)$ și $b=(b_1, b_2, \dots, b_M)$.

$$A \oplus B = \{z \in \mathbb{Z}^2 \mid z=a+b \text{ pt. un } a \in A \text{ și } b \in B\}$$


Ex: $A=\{(0,1), (1,1), (2,1), (2,2), (3,0)\};$

$$B=\{(0,0), (0,1)\}$$



$$A \oplus B = \{(0,1), (1,1), (2,1), (2,2), (3,0), (0,2), (1,2), (2,2), (2,3), (3,1)\}$$

Ex: $A=\{(1,2), (2,2), (3,2), (4,2)\};$ $B=\{(0,-1), (0,1)\}$




$$A \oplus B = \{(1,1), (2,1), (3,1), (4,1), (1,3), (2,3), (3,3), (4,3)\}$$


Modalitate practica de aplicare (laborator)

Se aplica elementul structural peste imaginea sursa


1. Daca originea elementului structural coincide cu un pixel ,0' (alb) din imaginea sursa nu fac nimic (trec la pixelul următor)
2. Daca originea elementului structural coincide cu un pixel ,1' negru (din imaginea sursa) realizez OR logic intre pixelii corespunzători elementului structural si pixelii corespunzători din imaginea sursa (asemănător convoluției – operația este OR logic si nu înmulțire aritmetica !!!)



a. Original image.



b. Structural element; x = origin.




c. Image after dilation; original in dashes.

Aplicații: Umplere goluri, unire legături slabe între obiecte (istmuri)



binarizare $\Rightarrow$





dilatare (obiect = negru) $\Rightarrow$



EROZIUNE

Eroziunea A cu B

$$A \ominus B = \{z | (\hat{B})_z \subseteq A\}$$




Alta definiție pt. eroziune

Eroziunea $\leftrightarrow$ dilatare (duale /complementare)

$$a=(a_1, a_2, \dots, a_N) \text{ și } b=(b_1, b_2, \dots, b_N).$$

$$A \ominus B = \{x \in \mathbb{Z}^2 \mid x + b \in A \text{ pt. orice } b \in B\}$$


Ex1: $A = \{(1,0), (1,1), (1,2), (1,3), (1,4), (1,5), (2,1), (3,1), (4,1), (5,1)\}$

$$B = \{(0,0), (0,1)\}$$
$$A \ominus B = \{(1,0), (1,1), (1,2), (1,3), (1,4)\}$$



Modalitate practica de aplicare (laborator)

Se aplica elementul structural peste imaginea sursa


1. Daca originea elementului structural (B) coincide cu un pixel 0 din imaginea sursa nu fac nimic (trec la pixelul următor)
2. Daca originea elementului structural (B) coincide cu un pixel 1 din imaginea sursa (pixel curent) si oricare (exista cel putin unul) dintre pixelii de 1 din elementul structural se extinde in afara obiectului (A) atunci schimb valoarea pixelului curent din imaginea sursa in 0.



a. Original image.




b. Structural element;
x = origin



c. Image after erosion; original in dashes.

Aplicații: Eliminarea obiectelor mici (zgomote), spargerea legăturilor slabe între obiecte (istmuri)



Imagine originală

eroziune (negru) $\Rightarrow$




Imagine rezultat după eroziune

Exemplu de aplicare tipica a operatiilor morfologice in segmentarea imaginilor:

Dorim sa segmentam mana care apare in imaginea de mai jos. Realizam o clasificare a pixelilor bazata pe un model de culoare a pielii (invatat anterior) $\Rightarrow$ o imagine cu „defecte/zgomote” (erori de clasificare a pixelilor) ”: pixeli albi in zona obiect si pixeli negrii in zona de fond.

- Aplicam o eroziune pt. a scapa de pixelii de „zgomot” din zona de fond (dreapta sus)
- Aplicam 2x dilatare pt. a scapa de „golurile” din zona obiect (dreapta jos)
- Aplicam o eroziune pt. a reduce obiectul la aria initiala / reala (stanga jos)



DESCHIDERE SI INCHIDERE

Deschidere

$$A \circ B = (A \ominus B) \oplus B$$

Aplicații: netezire contur, eliminare obiecte mici, spargere legaturi slabe intre obiecte (istmuri)

Închidere

$$A \bullet B = (A \oplus B) \ominus B$$

Aplicații: netezire contur, eliminare goluri mici din obiecte, unire legaturi slabe intre obiecte (istmuri)

Deschidere



Imagine rezultat după deschidere (obiect = negru)


Închidere




Imagine rezultat după închidere (obiect = negru)

Exemple:

Deschidere



Închidere



Proprietati (ale operatorilor morfologici)

1. $A \oplus B = B \oplus A$

2. $(A \ominus B)^C = A^C \oplus B$

3. $A \circ B \subseteq A$

4. $C \subseteq D \Rightarrow C \circ B \subseteq D \circ B$

5. $(A \circ B) \circ B = A \circ B$ (IDEMPOTENȚĂ)

6. $A \subseteq A \bullet B$


7. $C \subseteq D \Rightarrow C \bullet B \subseteq D \bullet B$

8. $(A \bullet B) \bullet B = A \bullet B$ (IDEMPOTENȚĂ)


Aplicatii ale operatiilor morfologice de baza

EXTRAGERE CONTUR


$$\beta^i(A) = A - (A \ominus B) \quad (\text{contur interior})$$




A



B



$A \ominus B$



$\beta^i(A)$

$$\beta^e(A) = (A \oplus B) - A \quad (\text{contur exterior})$$

UMPLERE REGIUNI


- p in interiorul conturului A (care se dorește a fi umplut in interior cu „1”)

1. $X_0 = p$, ($p = '1'$)


2. $X_k = (X_{k-1} \oplus B) \cap A^C \quad k=1,2,3,$

3. *Daca* $X_k = X_{k-1} \Rightarrow$ stop. Altfel repeta 2.


Obiectul final (umplut): $A \cup X_k$




A




A^c




B






X_0




X_1




X_2



X_6



X_7



$X_7 \cup A$

EXTRAGERE COMPONENTE CONEXE (ETICHETARE)






$A = \{ Y_1, Y_2, \dots, Y_n \}$, Y_i – componente conexe

$$Y \subseteq A$$

1. $p \in Y$. $X_0 = p$

2. $X_k = (X_{k-1} \oplus B) \cap A \quad k=1,2,3,\dots$

3. Dc. $X_k = X_{k-1} \Rightarrow \text{stop } (Y = X_k)$. Altfel repeta 2.



Y, p

B

X_1

X_2

$X_3 = Y$

TRANSFORMATĂ „HIT-AND-MISS”

Se folosește la selecția unor seturi de pixeli cu proprietăți geometrice specifice: colturi, puncte izolate, puncte de contur, *template matching* (obiecte cu o anumită formă), subțiere, îngroșare etc.

Transformat hit & miss a unui set A cu elementele structurale (J,K):

$$A \otimes (J,K) = (A \ominus J) \cap (A^c \ominus K).$$


Ex. 1: Thinning (subțiere)

0	0	0
	1	
1	1	1



J

	0	0
1	1	0
	1	

K




A




$A \otimes (J,K)$


Ex.2: Detecție colțuri




J




K




A




A^c



(A ⊖ J)




(A^c ⊖ K)



A ⊗ (J,K) = (A ⊖ J) ∩ (A^c ⊖ K)

SKELETIZAREA



„Skeletonul” setului A:

$$S(A) = \bigcup_{k=0}^K S_k(A)$$

$$S_k(A) = (A \ominus kB) - (A \ominus kB) \circ B$$

$$A \ominus kB = (... (A \ominus B) \ominus B) \dots \ominus B$$

$$K = \max\{k \mid (A \ominus kB) \neq \Phi\}$$

Reconstrucția setului A:

$$A = \bigcup_{k=0}^K (S_k(A) \oplus kB)$$

K – trebuie sa fie cunoscut

Referințe:

[1] Robert M. Haralick, Linda G. Shapiro, *Computer and Robot Vision*, Addison-Wesley Publishing Company, 1993

[2] Rafael C. Gonzalez, *Digital Image Processing*, Prentice-Hall, 2002



Technical University of Cluj - Napoca
Computer Science Department

Pocesarea Imaginilor

Curs nr. 6

Prelucrari pe imagini multinivel (grayscale) (I)

Proprietati statistice ale imaginilor grayscale si aplicatii. Imbunatatirea calitatii imaginilor



Statistical features / Trasaturi statistice


Trasaturi statistice $\Rightarrow$ trasaturi globale (calculate pe intreaga imagine sau pe o regiune de interes – ROI)

Gray-levels histogram (histograma nivelurilor de gri/intensitate)

Nivele de gri: $g \in [0 \dots L]$, L – nivelul max. (imagini 8biti/pixel : $L=255$)

$$h(g)=N_g$$

N_g – numarul de pixeli din imagine/ROI care au nivelul de intensitate egal cu g





Statistical features / Trasaturi statistice

Probability distribution function (of the gray-levels)

(functia distributiei de probabilitate a nivelurilor de gri)

$P(g)$:= probabilitatea ca nivelul de intensitate dintr-o regiune sa fie mai mica sau egala cu g :

$$0 \leq P(g) \leq 1$$

$$P(g) - \text{monoton crescatoare} \Rightarrow dP/dg \geq 0$$

Probability density function (of the gray-levels): $p(g)$

(functia densitatii de probabilitate a nivelurilor de gri)

$p(g)\Delta g$:= probabilitatea ca nivelul de intensitate dintr-o regiune sa fie cuprins intre g si $g+\Delta g$

$$p(g) \cdot \Delta g = \left(\frac{dP(g)}{dg} \right) \Delta g$$

$p(g)$ – histograma normalizata:

$$p(g) = \frac{h(g)}{M}, \quad \text{with: } \begin{cases} p(g) \geq 0 \\ \int_{-\infty}^{\infty} p(g) dg = 1, \quad \sum_{g=0}^L \frac{h(g)}{M} = \frac{M}{M} = 1 \end{cases}$$

$M = \text{image_height} \times \text{image_width}$



Statistical features / Trasaturi statistice

Mean (media)

⇒ Masura a intensitatii medii dintr-o imagine / ROI

$$\bar{g} = \mu = \int g \cdot p(g) dg = \sum_{g=0}^L g \cdot p(g) = \frac{1}{M} \sum_{g=0}^L g \cdot h(g) = \frac{1}{M} \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} I(i, j)$$

Image
“intunecata”





Image
“luminoasa”





Aplicatie: segmentare imagini grayscale

Basic global thresholding algorithm

- Calculeaza automat pragul de binarizare (T)
- Se poate aplica pe imagini cu histograma bimodala

Algoritmul

1. Take an initial value for T :

$$T_0 = \mu \text{ (object area = background area)}$$

$$T_0 = (g_{MAX} + g_{MIN})/2$$

2. Step k : segment the image after T_{k-1} by dividing the image pixels in 2 groups:



$$G1: I[i,j] < T_{k-1} \Rightarrow \mu_{G1}$$

$$G2: I[i,j] > T_{k-1} \Rightarrow \mu_{G2}$$

3. $T_k = (\mu_{G1} + \mu_{G2})/2$

4. Repeat 2-3 until $T_k - T_{k-1} < \varepsilon$

Implementare eficienta $\Rightarrow$ se va calcula mai intai histograma imaginii iar apoi toate calculele (μ_{G_i}) se vor face pe histograma !!!






Statistical features / Trasaturi statistice

Standard deviation (deviatia standard)

⇒ Masura a contrastului mediu al imaginii / ROI

$$\sigma = \sqrt{\sum_{g=0}^L (g - \mu)^2 \cdot p(g)} = \sqrt{\frac{1}{M} \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} (I(i, j) - \mu)^2}$$

Contrast
ridicat



Contrast
scazut






Image enhancement / Imbunatatirea calitatii imaginilor

Histogram slide / deplasarea histogramei

$$\text{Slide}(I[i,j]) = I[i,j] + \text{offset}$$

$\text{offset} > 0 \Rightarrow$ imagine mai “luminoasa”
 $\text{offset} < 0 \Rightarrow$ imagine mai “intunecata”








Image enhancement / Îmbunătățirea calitatii imaginilor


Histogram stretch/shrink (latire/îngustare a histogramei)

$$\text{Stretch/Shrink}(I[i,j]) = \text{Final}_{\text{MIN}} + (\text{Final}_{\text{MAX}} - \text{Final}_{\text{MIN}}) * (I[i,j] - g_{\text{MIN}}) / (g_{\text{MAX}} - g_{text{MIN}})$$



shrink

stretch



shrink

stretch





Image enhancement / Imbunatatirea calitatii imaginilor

Re-maparea nivelelor de gri folosind o functie de transformare

$$g_{\text{output}} = T(g_{\text{input}})$$

Ex. - gamma correction:

$$g_{\text{out}} = c \cdot g_{\text{in}}^{\gamma} \quad \text{sau} \quad \frac{g_{\text{out}}}{L} = c \cdot \left(\frac{g_{\text{in}}}{L} \right)^{\gamma}$$








Image enhancement / Imbunatatirea calitatii imaginilor

Ex. - gamma correction:



$\gamma < 1$: codificare/compresie gamma



$\gamma > 1$: decodificare/decompresie gamma



Statistical features / Trasaturi statistice

Informatia – informatia asociata nivelului de intensitate g :

$$I_g = -\log_2 p(g) \quad [bits]$$

⇒ informatia este ridicata cand este generat un nivel de gri cu probabilitate mica

Entropy – informatia medie din imagine:

$$H = -\sum_{g=0}^L p(g) \cdot \log_2 p(g) \quad [bits]$$

⇒ Cati biti avem nevoie pentru a codifica datele din imagine:

H (mare) – val. pixelilor sunt distribuite pe multe nivele de gri

$H_{\max} = \log_2 L$ [bits] (uniform PDF)

Energy – cum sunt distribuite nivelele de gri:

$$E = \sum_{g=0}^L [p(g)]^2$$

E (mica) – numarul de nivele de gri este mare

$E_{\max} = 1$ (un singur nivel de gri)



Histogram processing / Procesari pe histograma

Histogram equalization/ Egalizarea histogramei

Nivele de gri normalizate:


$$g \in [0 \dots L] \Rightarrow r \in [0 \dots 1]$$

Funcție de transformare:

$$s = T(r)$$

(a). Bijectiva si monoton crescatoare $\Rightarrow \exists r = T^{-1}(s)$



(b). $0 \leq T(r) \leq 1$





Histogram processing / Procesari pe histograma

Histogram equalization/ Egalizarea histogramei: rezultate





Histogram processing / Procesari pe histograma


Histogram equalization/ Egalizarea histogramei

- $p_r(r)$, $p_s(s)$ – FDP ale imaginii de intrare si iesire
- $p_r(r)$, $T(r)$ sunt cunoscute si T^{-1} satisface conditia (a)

$$p_s(s) = p_r(r) \left| \frac{dr}{ds} \right| \quad (1)$$

Historama cumulativa / FDP cumulativa (CDF)

$$s = T(r) = \int_0^r p_r(w) dw \quad (2)$$



T satisface (a) & (b)

Regula Leibniz: derivata unei integrale definite superior este chiar functia integrata evaluata in acea limita:

$$\frac{ds}{dr} = \frac{dT(r)}{dr} = \frac{d}{dr} \left[\int_0^r p_r(w) dw \right] = p_r(r) \quad (3)$$



Histogram processing / Procesari pe histograma

Histogram equalization/ Egalizarea histogramei


(1) + (3) $\Rightarrow$

$$p_s(s) = p_r(r) \left| \frac{dr}{ds} \right| = p_r(r) \left| \frac{1}{p_r(r)} \right| = 1, \quad 0 \leq s \leq 1$$

$p_s(s)$:

- PDF uniforma
- independenta de $p_r(r)$

Algoritmul de egalizare a histogramei



$$p_r(r_k) = \frac{n_k}{n}, \quad k = 0 \dots L, \quad r_k = k / L$$

$$s_k = T(r_k) = \sum_{j=0}^k p_r(r_j) = \sum_{j=0}^k \frac{n_j}{n}, \quad k = 0 \dots L$$

$\Rightarrow$ remapare nivele de gri ale imaginii de iesire: $r_k \rightarrow s_k$



Egalizarea histogramei - exemplu




Egalizare





Histogram processing / Procesari pe histograma

Histogram specification / matching (Specificarea histogramei)



Pentru imaginea de intrare : $s = T(r) = \int_0^r p_r(w)dw$ (1)

Se definește o variabilă aleatoare z cu proprietățile:

$$G(z) = \int_0^z p_z(t)dt = s \quad (2)$$

$$(1) + (2) \Rightarrow G(z) = T(r)$$

$$z = G^{-1}(s) = G^{-1}[T(r)]$$



Histogram processing

Histogram specification / matching (Specificarea histogramei)

$$r_k \leftrightarrow z_k$$

Nu se poate deduce o expresie analitica pt. G^{-1} !?

Algorithm:

$$1. \quad r_k \leftrightarrow s_k: \quad s_k = T(r_k) = \sum_{j=0}^k p_r(r_j) = \sum_{j=0}^k \frac{n_j}{n}, \quad k = 0 \dots L$$


$$2. \quad z_k \leftrightarrow v_k: \quad v_k = G(z_k) = \sum_{j=0}^k p_z(z_j) = s_k, \quad k = 0 \dots L$$

$$3. \quad s_k \leftrightarrow z_k:$$

Fie $z' = z_k$, $k = 0, \dots, L$

z_k va fi cea mai mica valoare a lui z' care satisface conditia:

$$(G(z') - s_k) \geq 0$$






Metoda Otsu (calculul pragului de binarizare)

Definirea problemei

- Avem două grupuri de pixeli, care se întind pe domenii de intensități diferite (ex: obiecte și fundal). Problema selecției unui prag este complicată de faptul că aceste domenii de intensitate uneori se suprapun parțial. Se dorește minimizarea erorilor de clasificare a unui pixel obiect ca fundal, și viceversa.
- Pentru realizarea acestui deziderat, încercăm să minimizăm aria de sub histograma unei regiuni, care pe baza pragului calculat va fi atribuită celeilalte regiuni. Vom considera aceste două regiuni ca două grupuri.
- Pragul va fi ales astfel ca cele două grupuri să fie cât mai “strânse”, minimizând astfel suprapunerea.
- O măsură a omogenității grupului este varianța. Un grup cu omogenitate mare are o varianță mică, un grup cu omogenitate mică are varianță mare.



Metoda Otsu



Histograme de nivele de gri approximate prin două distribuții normale. Pragul se alege pentru a avea probabilitatea minimă de a segmenta greșit.

a) Distribuția de probabilitate a fundalului și a obiectelor

b) Histograma rezultată, și pragurile optime



Metoda Otsu

Varianța ponderată intra-clasă este: $\sigma_w^2(t) = q_1(t)\sigma_1^2(t) + q_2(t)\sigma_2^2(t)$

Probabilitățile asociate claselor sunt estimate ca: $q_1(t) = \sum_{i=1}^t P(i)$ $q_2(t) = \sum_{i=t+1}^I P(i)$
unde $P(i) = \frac{H(i)}{N^2}$

Mediile claselor sunt definite ca: $\mu_1(t) = \sum_{i=1}^t \frac{iP(i)}{q_1(t)}$ $\mu_2(t) = \sum_{i=t+1}^I \frac{iP(i)}{q_2(t)}$

Varianțele individuale ale claselor sunt definite ca:

$$\sigma_1^2(t) = \sum_{i=1}^t [i - \mu_1(t)]^2 \frac{P(i)}{q_1(t)} \quad \sigma_2^2(t) = \sum_{i=t+1}^I [i - \mu_2(t)]^2 \frac{P(i)}{q_2(t)}$$

În acest moment avem toate ecuațiile necesare pentru a măsura varianța ponderată intra-clasă. Am putea să verificăm fiecare posibilă valoare a pragului t , și să o alegem pe cea care minimizează această varianță.

- Totuși, relația dintre varianța intra-clasă și varianța dintre clase se poate exploata pentru a găsi o recursivitate ce permite un calcul mai rapid.

Notatii: P – FDP, q – probabilitate ($q(t)$ – FDP cumulativă a lui P)



Metoda Otsu

Varianța totală a imaginii este:

$$\begin{aligned} \sigma^2 &= \sum_{i=1}^I [(i - \mu)^2 P(i)] \quad \mu = \sum_{i=1}^I i P(i) \\ \sigma^2 &= \sum_{i=1}^t [i - \underbrace{\mu_1(t) + \mu_1(t) - \mu}_{\text{red bracket}}]^2 P(i) + \sum_{i=t+1}^I [i - \underbrace{\mu_2(t) + \mu_2(t) - \mu}_{\text{red bracket}}]^2 P(i) \\ &= \sum_{i=1}^t \{ [i - \mu_1(t)]^2 + 2[i - \mu_1(t)][\mu_1(t) - \mu] + [\mu_1(t) - \mu]^2 \} P(i) \\ &\quad + \sum_{i=t+1}^I \{ [i - \mu_2(t)]^2 + 2[i - \mu_2(t)][\mu_2(t) - \mu] + [\mu_2(t) - \mu]^2 \} P(i) \end{aligned}$$

Dar: $\sum_{i=1}^t [i - \mu_1(t)][\mu_1(t) - \mu] P(i) = 0$ $\sum_{i=t+1}^I [i - \mu_2(t)][\mu_2(t) - \mu] P(i) = 0$

Astfel $\Rightarrow \sigma^2 = \sum_{i=1}^t [i - \mu_1(t)]^2 P(i) + [\mu_1(t) - \mu]^2 q_1(t) + \sum_{i=t+1}^I [i - \mu_2(t)]^2 P(i) + [\mu_2(t) - \mu]^2 q_2(t)$

$$\sigma^2 = [q_1(t)\sigma_1^2(t) + q_2(t)\sigma_2^2(t)] + \{q_1(t)[\mu_1(t) - \mu]^2 + q_2(t)[\mu_2(t) - \mu]^2\}$$

$$\mu = q_1(t)\mu_1(t) + q_2(t)\mu_2(t)$$

$$1 - q_1(t) = q_2(t)$$

$$\Rightarrow \sigma^2 = \sigma_w^2(t) + q_1(t)[1 - q_1(t)][\mu_1(t) - \mu_2(t)]^2$$



Metoda Otsu

Pentru orice prag, varianța totală a imaginii este suma dintre varianța intra-clasă, și varianța dintre clase.

$$\sigma^2 = \underbrace{\sigma_w^2(t)}_{\text{varianța intra-clasă}} + \underbrace{q_1(t)[1 - q_1(t)][\mu_1(t) - \mu_2(t)]^2}_{\text{varianța dintre clase}}$$

-Deoarece varianța totală este constantă, independentă de pragul t , efectul alegerii pragului este doar de a schimba ponderea celor două varianțe.

-Problema minimizării varianței intra-clasă este astfel echivalentă cu problema maximizării varianței dintre clase.

-Acest lucru se poate face recursiv.



Metoda Otsu

Inițializare: $q_1(1) = P(1) \quad ; \quad \mu_1(0) = 0$

Recursivitate: $q_1(t+1) = q_1(t) + P(t+1)$

$$\mu_1(t+1) = \frac{q_1(t)\mu_1(t) + (t+1)P(t+1)}{q_1(t+1)}$$

$$\mu_2(t+1) = \frac{\mu - q_1(t+1)\mu_1(t+1)}{1 - q_1(t+1)}$$

Pentru fiecare prag potențial t:

1. Se separă pixelii în două clase, pe baza pragului
2. Se calculează media celor două clase
3. Se calculează varianța dintre clase, conform ecuației de pe slide-ul anterior

Se reține pragul t care maximizează această varianță.

https://en.wikipedia.org/wiki/Otsu%27s_method



Aplicatie: segmentare imagini grayscale

Metoda OTSU pt. praguri multiple:

G. X.Ritter, J.N. Wilson, Handbook of computer vision algorithms in image algebra - 2nd ed, 2001 CRC Press: Cap. 4.7. Threshold Selection by Maximizing Between-Class Variance.



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

Curs 7:

Convolutie. Transformata Fourier



Notiuni preliminare

Imagine “continua” := functie continua de 2 variabile independente

Exemple: $u(x, y)$; $v(x, y)$; $f(x, y)$

Functie 2D separabila:

$$f(x, y) = f_1(x)f_2(y)$$

Imagine discreta (digitala) := secventa 2D (bidimensionala) de numere reale/intregi

Exemple: $u_{m,n}$; $v(m, n)$

Notatii:

k, l, m, n – indici intregi folositi in matrice, vectori:

$$\mathbf{j} = \sqrt{-1}$$



Convolutie


Funcția Dirac (impuls unitar $\Rightarrow$ Aria = 1)

Funcția Dirac 2D (continua):


$$\delta(x,y) = \delta(x)\delta(y)$$

Funcția discretă – Kronecker:

$$\delta(m,n) = \delta(m)\delta(n)$$



Sistem



Sistem liniar (principiul superpoziției liniare):

$$\begin{aligned}\mathcal{H}[a_1x_1(m,n) + a_2x_2(m,n)] &= a_1\mathcal{H}[x_1(m,n)] + a_2\mathcal{H}[x_2(m,n)] \\ &= a_1y_1(m,n) + a_2y_2(m,n)\end{aligned}$$




Iesirea unui sistem liniar

$$\begin{aligned} y(m, n) &= \mathcal{H}[x(m, n)] \\ &= \mathcal{H} \left[\sum_{m'} \sum_{n'} x(m', n') \delta(m - m', n - n') \right] \\ &= \sum_{m'} \sum_{n'} x(m', n') \mathcal{H} [\delta(m - m', n - n')] \end{aligned}$$

$$y(m, n) = \sum_{m'} \sum_{n'} x(m', n') h(m, n; m', n')$$

Unde: $h(m, n; m', n')$ Este **raspunsul la impuls al sistemului** – iesirea sistemului H in punctul/locatia (m, n) atunci cand la intrare se aplica functia impuls unitar (Kronecker) la locatia (m', n') .




Dc. $y(m, n), x(m, n) > 0$ (ex: imagini), atunci h s.n. **Points Spread Function (PSF)**



Convolutie

Regiune suport a raspunsului la impuls := cea mai mica regiune din planul (m,n) cu proprietatea ca in afara acestei regiuni raspunsul la impuls (h) este nul.



Sisteme **FIR** – sisteme a caror raspuns la impuls au o regiune suport **finita**

Sisteme **IIR** – sisteme a caror raspuns la impuls au o regiune suport **infinita**

Sistem invariant la translatie := sistem pt. care o translatie a intrarii va determina o translatie corespunzatoare a iesirii

⇒ forma raspunsului la impuls nu se schimba odata cu deplasarea impulsului in planul (m,n)


Convolutia intarii cu raspunsul la impuls:

$$y(m, n) = \sum_{m'=-\infty}^{\infty} \sum_{n'=-\infty}^{\infty} h(m - m', n - n') x(m', n')$$



Convolutie


Convolutie 1D



Convolutie 2D

$$g(x, y) = h(x, y) * f(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x - x', y - y') f(x', y') dx' dy'$$

$$y(m, n) = h(m, n) * x(m, n) = \sum_{m'=-\infty}^{\infty} \sum_{n'=-\infty}^{\infty} h(m - m', n - n') x(m', n')$$






Operația de convoluție în domeniul spațial

Operația de convoluție implică folosirea unei măști/nucleu de convoluție H (de obicei de formă simetrică de dimensiune $w \times w$, cu $w=2k+1$) care se aplică peste imaginea sursă:

$$I_D = H * I_S$$

$$I_D(x, y) = \sum_{i=-k}^k \sum_{j=-k}^k H(i, j) \cdot I_S(x+i, y+j), \quad x = 0 \dots \text{Height} - 1, \quad y = 0 \dots \text{Width} - 1$$





Convolutie

Exemplu: filtru pt. detectia muchilor verticale (calculeaza derivata imaginii pe directia x)

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

ImgSrc (i,j)



$$\text{ImgDst}(i,j) = G_x * \text{ImgSrc}(i,j)$$





Transformata Fourier [1]

Notiuni preliminare

Functie periodica $\Rightarrow$ **serii Fourier** (suma sin si cos de frecvente diferite)


Functie integrala (arie) finita $\Rightarrow$ **transformata Fourier** (integrala / suma de sin si cos)

Transformata Fourier (1D)

$$F(u) = \int_{-\infty}^{\infty} f(x) e^{-j2\pi ux} dx$$
$$e^{jx} = \cos(x) + j \sin(x)$$

Transformata Fourier inversa (1D)

$$f(x) = \int_{-\infty}^{\infty} F(u) e^{j2\pi ux} du$$



$\Rightarrow$ Se poate reface functia initiala plecand de la functia transformata !!!



Transformata Fourier [1]

Transformata Fourier (2D):

$$F(u, v) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) e^{-j2\pi(ux+vy)} dx dy$$

$$f(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} F(u, v) e^{j2\pi(ux+vy)} du dv$$

Transformata Fourier discreta - DFT (1D):

$$F(u) = \frac{1}{M} \sum_{x=0}^{M-1} f(x) e^{-j2\pi ux/M} \quad u = 0, 1, 2, \dots, M-1 \text{ (domeniu de frecvente)}$$

$$F(0) = \dots, F(1) = \dots, \dots, F(M-1) = \dots \text{ (componente de frecventa)}$$

$$f(x) = \sum_{u=0}^{M-1} F(u) e^{j2\pi ux/M} \quad x = 0, 1, 2, \dots, M-1 \text{ (domeniu spatial)}$$





Transformata Fourier [1]

Caracteristici ale DFT

$F(u)$ exprimata in coordonate polare: $F(u) = |F(u)|e^{-j\phi(u)}$

Magnitudine (spectru) $\Rightarrow$ **image enhancement** $|F(u)| = [R^2(u) + I^2(u)]^{1/2}$



Faza (spectru de faza / unghi de faza)

$$\phi(u) = \tan^{-1} \left[\frac{I(u)}{R(u)} \right]$$

Spectru de putere (densitate spectrala)

$$P(u) = |F(u)|^2 = R^2(u) + I^2(u)$$



Transformata Fourier [1]

Transformata Fourier discreta – DFT (2D)

$$F(u, v) = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi(ux/M + vy/N)}$$

$u = 0, 1, 2, \dots, M-1, v = 0, 1, 2, \dots, N-1$ (coordonate/varibile de **frecventa**)

$$f(x, y) = \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) e^{j2\pi(ux/M + vy/N)}$$

$x = 0, 1, 2, \dots, M-1, y = 0, 1, 2, \dots, N-1$ (coordonate/varibile **spatiale**)

Spectru: $|F(u, v)| = [R^2(u, v) + I^2(u, v)]^{1/2}$

Faza: $\phi(u, v) = \tan^{-1} \left[\frac{I(u, v)}{R(u, v)} \right]$

Spectru de putere: $P(u, v) = |F(u, v)|^2$
 $= R^2(u, v) + I^2(u, v)$




Transformata Fourier [1]

“Shift”-area transformatei Fourier:

$$\mathfrak{S}[f(x, y)(-1)^{x+y}] = F(u - M/2, v - N/2)$$

$\Rightarrow$ Spectru Fourier $F(u, v)$ centrat



Componenta continua a spectrului:

$$F(0, 0) = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \Rightarrow \text{intensitatea medie a imaginii}$$

Pt. Imagini ($f \in \mathbb{R}$): $|F(u, v)| = |F(-u, -v)|$


Relatiile dintre esantioanele spatiale si frecventiale ale imaginii:

$$\Delta u = \frac{1}{M\Delta x} \quad \Delta v = \frac{1}{N\Delta y}$$



Transformata Fourier [1]

Exemple de reprezentare a DFT






Transformata Fourier


Transformata directa



Original




$\log(|F(u,v)|)$



$\phi(u,v)$

Transformata inversa



$\phi(u,v)=0$ (se ignora faza)




$|A(u,v)|=0$ (se ignora amplitudinea)



Transformata Fourier [1]

Filtrarea imaginilor in domeniul frecventelor $f(x, y) * h(x, y) \Leftrightarrow F(u, v)H(u, v)$

$$f(x, y)h(x, y) \Leftrightarrow F(u, v) * H(u, v)$$





1. Multiply the input image by $(-1)^{x+y}$ to center the transform, as indicated in Eq. (4.2-21).
2. Compute $F(u, v)$, the DFT of the image from (1).
3. Multiply $F(u, v)$ by a *filter* function $H(u, v)$. $G(u, v) = H(u, v)F(u, v)$
4. Compute the inverse DFT of the result in (3). Filtered Image = $\mathfrak{F}^{-1}[G(u, v)]$
5. Obtain the real part of the result in (4).
6. Multiply the result in (5) by $(-1)^{x+y}$.




Transformata Fourier [1]

Filtrarea imaginilor in domeniul frecventelor – exemple:



Negativul imaginii:


$$H(u, v) = \begin{cases} 0 & \text{if } (u, v) = (M/2, N/2) \\ 1 & \text{otherwise.} \end{cases}$$







Transformata Fourier [1]

Filtrarea imaginilor in domeniul frecventelor – exemple:



FTJ




FTS



Transformata Fourier [1]







Filtrarea imaginilor in domeniul frecventelor – exemple:





Transformata Fourier [1]


Filtrarea imaginilor in domeniul frecventelor – exemple: FTJ







Transformata Fourier [1]

Filtrarea imaginilor in domeniul frecventelor – exemple: FTJ ideal



$$H(u, v) = \begin{cases} 1 & \text{if } D(u, v) \leq D_0 \\ 0 & \text{if } D(u, v) > D_0 \end{cases}$$




$$D(u, v) = [(u - M/2)^2 + (v - N/2)^2]^{1/2}$$






Transformata Fourier [1]

Filtrarea imaginilor in domeniul frecventelor – exemple: FTJ Gaussian



$$H(u, v) = e^{-D^2(u, v)/2D_0^2}$$

$$D(u, v) = [(u - M/2)^2 + (v - N/2)^2]^{1/2}$$





[1] R.C.Gonzales, R.E.Woods, "Digital Image Processing, 2-nd Edition", *Prentice Hall*, 2002, pp 147-177



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

Curs 8:

Prelucrari pe imagini multinivel (grayscale) (III)

Filtre digitale



Filtrarea digitala a imaginilor

Filtrarea digitala - una dintre cele mai utilizate tehnici in procesarea imaginilor $\Rightarrow$ detectie muchii, eliminare zgomote, restaurare imagini

2 clase principale de filtre:

- **liniare**: iesirea este o combinatie liniara a valorilor pixelilor de intrare

$\Rightarrow$ se aplica prin operatorul de convolutie

ex: medie aritmetica, medie ponderata ...

- **neliniare**: iesirea este o combinatie ne-liniara a valorilor pixelilor de intrare

$\Rightarrow$ modul de aplicare este dependent de tipul filtrului

ex: minim, maxim, elem. median



Filtre digitale liniare

Obiectiv: convolutia imaginii $f(i,j)$ cu functia de filtrare $h(i,j)$

In spatiul Real (coordonate imagine):

$$g(i, j) = h(i, j) \odot f(i, j)$$

In spatiul Fourier (spatiul frecventelor) $\Rightarrow$ teorema convolutiei:

$$G(k, l) = H(k, l) F(k, l)$$

Operatia de filtrare este controlata de forma functiei de filtrare:

$h(i,j)$ in spatiul Real

$H(k,l)$ in spatiul Fourier

Cele doua modalitati de aplicare sunt identice ca si efect, dar difera d.p.d.v. al efortului de calcul.



Convolutia in spatiul Fourier (frecvente)

$$g(i, j) = F^{-1} \{H(k, l) F(k, l)\}$$

Efortul de calcul:

2x DFT + 1x inmultire complexa (operatii cu virgula)

daca $H(k, l)$ se deduce din $h(i, j) \Rightarrow$ 1x DFT

Costul de calcul nu depinde de tipul (dimensiunea) filtrului: $h(i, j)$

Se poate aplica doar pt. operatii de filtrare liniare


NU se poate aplica pt. operatii de filtrare ne-liniare



Convolutia in spatiul Real (coordonate imagine)

Pentru un filtru $h(i,j)$ de dimensiune $M \times M$ se definește ca:

$$g(i,j) = \sum_{m,n=-M/2}^{M/2} h(m,n)f(i-m,j-n)$$



Schema “shift & multiply”
Operatii pe tip intreg / byte
sau float/double

Costul de calcul $\sim M^2$ (depinde de dimensiunea filtrului)



Convolutie in spatiul Real sau Fourier?

Costul convolutiei in spatiul Real depinde de dimensiunea Filtrului

Costul convolutiei in spatiul Fourier – fix (depinde de costul DFT si ‘op. inmultire’)

In functie de tipul platformei hardware exista o limita a dimensiunii filtrului sub care aplicarea convolutiei in spatiul Real este mai eficienta decat aplicarea convolutiei in spatiul Fourier

Daca se depaseste aceasta limita pentru dimensiunea filtrului, aplicarea convolutiei in spatiul Fourier este mai eficienta (cost de calcul mai scazut).




Filtrarea in spatiul Fourier

- Modifica transformata Fourier a imaginii de intrare: $F(k,l)$
- Depinde de forma filtrului: $H(k,l)$

Imaginea de intrare / iesire $\Rightarrow$ **Reale** (majoritatea aplicatiilor)

Transformata Fourier complexa a imaginilor reale $\Rightarrow$ **proptietati de simetrie**:

- Partea **Reala simetrica**
- Partea **Imaginara anti-simetrica**



Pentru ca imaginea de iesire sa fie Reala $\Rightarrow$ filtrul Fourier trebuie sa respecte proprietatile de simetrie



Filtre trece jos (low-pass)

- Permit trecerea neatenuata a frecventelor spatiale joase
- Atenuaeaza sau blocheaza trecerea frecventelor inalte
- Folosite in reducerea zgomotului din imagini

Filtrul trece jos ideal $\Rightarrow$ blocheaza toate frecventele mai mari decat o frecventa de taiere (cut-off frequency) ω_0 :

$$H(k, l) = \begin{cases} 1 & k^2 + l^2 \leq \omega_0^2 \\ 0 & \text{else} \end{cases}$$

Filtrul trece jos in spatiul Real:


$$h(i, j) = \frac{J_1(r/\omega_0)}{r/\omega_0}$$
$$r^2 = i^2 + j^2.$$



Filtrul trece jos ideal - exemplu




Input image




Low-pass filter

Dimensiune imagine: 128 x 128

Frecv. taiere: 15 pixeli



Real space filter



Filtered Image

Imaginea rezultata după aplicarea filtrului trece-jos ideal are aspect de undă circulară la variații bruste ale intensității din imagine $\Rightarrow$ nefolositor



Filtrul trece-jos Gaussian

$$H(k, l) = \exp \left(-\frac{w^2}{w_0^2} \right) \quad w^2 = k^2 + l^2$$

Latimea filtrului w_0 ($k^2 + l^2 = w_0^2$) este valoarea pt. care gaussianul $H(k, l)$ este $1/e$.

In spatiul Real se obtine tot un filtru gaussian:

$$h(i, j) = \frac{\pi}{w_0^2} \exp \left(-\pi^2 w_0^2 r^2 \right) \quad r^2 = i^2 + j^2.$$

Filtrul este infinit atat in spatiul Fourier cat si in cel Real $\Rightarrow$ atenueaza frecventele inalte, fara sa le inlature complet ca si filtrul ideal.

Efecte: **netezirea imaginii** (“smoothing”), **fara efecte de unda circulara** (“ringing”).


De obicei se aplica inainte de o segmentare (bazata pe regiuni sau pe muchii) pentru eliminarea zgomotului (frecv. inalte)



Filtrul trece-jos Gaussian - exemplu




(a) Input image




(b) Low-pass filter

Dimensiune imagine:
128 x 128

$$\omega_0 = 30 \text{ pixeli}$$



(c) Filter in real space.



(d) Filtered Image




Filtrul Butterworth

$$H(k, l) = \frac{1}{1 + \left(\frac{w}{w_0}\right)^n}$$

ω_0 - punctul in care $H(k, l) = 1/2$

n – ordinul filtrului



Filtrul trapezoidal

$$H(k, l) = \begin{cases} = 1 & \text{for } w < w_0 \\ = \frac{(w-w_1)}{(w_0-w_1)} & \text{for } w_0 \leq w \leq w_1 \\ = 0 & \text{for } w > w_1 \end{cases}$$


Introducece efect de unda circulara (mai puternic decat cel Gaussian sau Butherworth dar mai slab decat cel Ideal)




Filtre trece-sus (high-pass)

- Permit trecerea neatenuata a frecventelor spatiale inalte
- Atenuaeza sau blocheaza trecerea frecventelor joase
- Folosit la accentuarea frecventelor inalte (muchii)

Filtrul trece sus ideal $\Rightarrow$ blocheaza toate frecventele mai mici decat o frecventa de taiere (cut-off frequency) ω_0 :



Filter



Output Image

Imaginea rezultata după aplicarea filtrului trece-sus ideal are aspect de undă circulară $\Rightarrow$ nefolositor

$$\omega_0 = 25$$




Filtru trece-sus Gaussian


- Realizeaza o reducere gradata a frecventelor joase
- Frecventele inalte trec prin filtru nealterate

$$H(k, l) = 1 - \exp\left(-\frac{w}{w_0}\right)^2 \quad w^2 = k^2 + l^2,$$

In spatiul Real $\Rightarrow$ filtru $h(i, j)$ cu variatie gradata $\Rightarrow$ accentuarea frecventelor inalte (ex: muchii) fara fect de unda circulara (“ringing”)



Filter



Output Image

In practica, acest filtru se combina cu un Gaussian trece jos $\Rightarrow$ Difference of Gaussian (DOG)

$$\omega_0 = 25$$




Alte filtre trece-sus

Filtrul Butterworth trece-sus

$$H(k, l) = 1 - \frac{1}{1 + \left(\frac{w}{w_0}\right)^n} = \frac{1}{1 + \left(\frac{w_0}{w}\right)^n}$$

ω_0 - punctul in care $H(k, l) = 1/2$


n – ordinul filtrului





Filtrarea in spatiul Real

Filtrul este specificat in spatiul Real printr-o masca $h(i,j)$ de dimensiune finita: 3×3 , 5×5 , 7×7



Elementele $h(i,j)$ sunt reale (intregi sau flotante)

Pentru masti mai mari de 7×7 folosirea filtrarii in spatiul Fourier poate fi mai rapida



Filtre de medie in spatiul Real

Inlocuiesc fiecare pixel cu media vecinilor $\Rightarrow$ efect low-pass (reducere a zgomotului)

Exemple:


5 Pixel Average

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

9 Pixel Average

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$



Input Image



Fourier Transform




5 point ave



Fourier Transform



9 point ave



Fourier Transform



Derivata in spatiul real

Derivata unei functii continue 1D:

$$\frac{df(x)}{dx} = \lim_{\delta \rightarrow 0} \frac{f(x + \delta) - f(x)}{\delta}$$


Pentru cazul discret ($\delta = 1$): $\frac{df(i)}{di} = f(i+1) - f(i)$

Procesul de derivare se poate exprima printr-o operatie de convolutie:

$$\frac{df(i)}{di} = [-1 \quad 1] \odot f(i)$$

Pentru ($\delta = 2$):

$$\frac{df(i)}{di} = [-1 \quad 0 \quad 1] \odot f(i)$$






Derivata de ordin 2

Derivata de ordin 2 a unei functii discrete 1D:

$$\frac{d^2 f(i)}{di^2} = f(i+1) - 2f(i) + f(i-1)$$

Sau exprimata prin convolutie: $\frac{d^2 f(i)}{di^2} = [1 \quad -2 \quad 1] \odot f(i)$



Datorita faptului ca operatia de convolutie este liniara, remarcam ca:

$$[1 \quad -2 \quad 1] = [-1 \quad 1] \odot [-1 \quad 1]$$



Derivate 2D

In cazul bi-dimentional (imagini reale) avem:

$$\frac{\partial f(i,j)}{\partial i} = [-1 \quad 0 \quad 1] \odot f(i,j)$$

$$\frac{\partial f(i,j)}{\partial j} = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} \odot f(i,j)$$


Pentru atenuarea zgomotului se practica medierea derivatelor pe 3 linii / coloane:

$$\frac{\partial f(i,j)}{\partial i} = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \odot f(i,j)$$


$$\frac{\partial f(i,j)}{\partial j} = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \odot f(i,j)$$

Efecte: evidentierea muchiilor verticale / orizontale

Obs: valorile rezultate in urma convolutiei cu un FTS $\Rightarrow$ scalare in intervalul 0 .. 255 (vezi L9 / 9.4,1)



x-differential



y-differential




Derivata in spatiul Fourier

Proprietatile transformatei Fourier:


$$F \left\{ \frac{\partial f(x,y)}{\partial x} \right\} = i2\pi u F(u,v) \qquad F \left\{ \frac{\partial f(x,y)}{\partial y} \right\} = i2\pi v F(u,v)$$

⇒ Derivarea in spatiul Fourier ≡ inmultire cu $i2\pi u$ sau $i2\pi v$

⇒ Efect high-pass (accentuarea frecventelor inalte)



x-differential (FT)



y-differential (FT)

Pe langa liniile “negre” (zero) orizontale si verticale centrale mai apar linii de “zero” secundare datorita efectului de mediere).



Derivata de ordin 2

$$\frac{\partial^2 f(i, j)}{\partial i^2} = [1 \quad -2 \quad 1] \odot f(i, j)$$



$$\frac{\partial^2 f(i, j)}{\partial j^2} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix} \odot f(i, j)$$

Laplacianul:
$$\nabla^2 f(i, j) = \frac{\partial^2 f(i, j)}{\partial i^2} + \frac{\partial^2 f(i, j)}{\partial j^2} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} \odot f(i, j)$$

Proprietatile transformatei Fourier:

$$F \{ \nabla^2 f(x, y) \} = -(2\pi w)^2 F(u, v) \quad w^2 = u^2 + v^2,$$

Efecte $\Rightarrow$ accentuarea
muchiilor din imagine in toate
directiile





Variatii ale Laplacian-ului

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix} \Rightarrow \text{Laplacian mai puțin sensibil la zgomot}$$

Accentuarea muchiilor: scăderea din imagine a Laplacian-ului

$$f(i, j) - \nabla^2 f(i, j) = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix} \odot f(i, j)$$



Input image



Edge Enhanced



Utilizarea filtrelor liniare

Filtre low-pass: netezirea imaginilor, diminuarea efectelor zgomtelor (se folosesc de obicei inaintea aplicarii detectorilor de puncte de muchie)

Filtre high-pass (filtre derivative): accentuarea frecventelor inalte (muchii).

Filtrele pot fi combinate (ex: low pass + high pass).

Datorita caracterului liniar, combinarea se poate face prin inmultire in spatiu Fourier si convolutie in spatiul Real.



Filtre neliniare in spatiul Real


$$g(i, j) = O_{m, n \in w}[h(m, n)f(i - m, j - n)]$$

Domeniul de definitie al mastii $h(m, n)$ dat de w .

Operatia de filtrare este definita de masca $h(i, j)$ si operatorul $O[]$.

La majoritatea filtrelor neliniare avem: $h(i, j) = 1 \quad i, j \in w$

operatia de filtrare fiind controlata de operatorul $O[]$






Filtre “shrink & expand”

Shrink = îngustare; Expand = largire

$O[] = \text{Min}[] \Rightarrow$ shrink: obiecte sunt reduse in dimensiune cu un ordin de marime egal cu dimensiunea filtrului

$O[] = \text{Max}[] \Rightarrow$ expand: obiecte sunt extinse in dimensiune cu un ordin de marime egal cu dimensiunea filtrului

$\Rightarrow$ Cele doua filtre sunt folosite in pereche pe imagini binare pentru eliminarea regiunilor mici / izolate



Obs: aplicarea
filtrelor nu este
comutativa:

$$E[S[f(i, j)]] \neq S[E[f(i, j)]]$$



Filtre shrink/expand 2D

Exemplu: fereastra 1D de dimensiune 3 (din exemplul anterior) $\Rightarrow$ fereastra 2D de dimensiune 3x3

Efect: eliminarea obiectelor (**pixel obiect = pixel alb**) mici/izolate dintr-o imagine binara

Exemplu filtrare shrink&expand cu un filtru de dimensiune 4x4:



Input



Binary Threshold



Binary Shrink



Binary Expand



Filtrul Threshold Average

Compara fiecare pixel cu media vecinilor (exclusiv valoarea lui) si netezeste (inlocuieste pixelul curent) doar daca diferenta este semnificativa.

Pentru fiecare pixel se calculeaza:

$$A = \sum_{m,n=-M/2}^{M/2} h(m,n) f(i-m, j-n)$$

Ex. - pt. un filtru 3x3: $h(i,j) = \begin{bmatrix} k & k & k \\ k & 0 & k \\ k & k & k \end{bmatrix}$ $k = 1/(M^2 - 1) = 0.125$

$$g(i,j) = \begin{cases} A & |A - f(i,j)| > T \\ f(i,j) & \text{else} \end{cases}$$

Stabilirea T: “trial and error” (~ fractiune din (Max(f) - Min(f)))



Filtrul median


$$O[] = \text{Median}[]$$

Median := elementul de mijloc dintr-o multime sortata

Exemplu:

$$f(i) = 61, 10, 9, 11, 9 \quad \text{Median}[f(i)] = 10$$


In cazul 1D filtrul median elimina toate trasaturile/obiectele cu dimensiune mai mica decat $M/2+1$, pastrand toate celelalte trasaturi






Proprietati (filtrul median)


Netezire fara alterarea punctelor de muchie (low-pass selectiv:



Input



Median (any length)



Average (length 5)

In cazul 2D elimina toate trasaturile (obiectele) cu dimensiunea (“aria”) mai mica de $M^2/2-1$, pastrandu-le pe toate celelalte



3 × 3 Median



5 × 5 Median



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

Curs 9:

Prelucrari pe imagini multinivel (grayscale) (IV)

Zgomote in imagini digitale. Modelarea si eliminarea lor.



Definitia zgomotului

Zgomot := Orice proces (n) care afecteaza imaginea (f) si nu face parte din scena (semnalul initial - s):


$$f(i,j) = s(i,j) + n(i,j) \text{ (modelul zgomotului aditiv)}$$

Cauze:

1. Natura discreta radiatiei
2. Sensibilitatea detectorului (sensibilitate variabila a elementelor din senzorul CCD/CMOS $\Rightarrow$ fixed pattern noise (dark current noise **(DCN)** & photon response nonuniformity **(PhRNU)**)
3. *Zgomot electric*
4. *Erori de transmisie a datelor*
5. *Turbulente atmosferice*
6. *Rezolutia senzorului (cuantizarea spatiala)*
7. *Digitizarea semnalului video (cuantizarea nivelelor de culoare / intensitate)*

Tipuri de zgomot (in functie de forma FDP $p(g)$):

- **Salt&pepper (sare si piper)**
- **Uniform**
- **Gaussian**
- *Alte distributii: Rayleigh, Erlang/Gamma, Exponential etc.*



$s(i,j)$ - semnal inițial (lumina reflectată de pe obiectul în scenă)
 $f(i,j)$ - semnalul (imaginea digitală) memorat în sistemul de calcul
 $u(i,j)$ - zgomot: procese care se interpun ① + ② + ... + ⑦

- ① Natura discretă a radiației
- ② Sensibilitatea variabilă a elementelor/pixelilor din senzor.
- ③ Zgomotul electric
- ④ Erori de transmitere a datelor.

- ⑤ Turbulențe atmosferice
- ⑥ Rezoluția senzorului (rezoluția de cuantizare spațială)
- ⑦ Digitizarea semnalului electric → semnal digital (rezoluția de culoare/intensitate).




Zgomot Salt &Pepper (sare si piper)

Cauze

- functionarea proasta a celulelor din senzorii camerelor
- greseli ale locatiilor de memorie
- erori de sincronizare in procesul de digitizare
- erori (pierderi de biti) pe canalul de comunicatie in cazul transmisilor imaginilor (ex: transmisii prin satelit in conditi atmosferice proaste).

Model

$$FDP_{Sare\&piper} = \begin{cases} A & \text{pentru } g = a \text{ ("piper")} \\ B & \text{pentru } g = b \text{ ("sare")} \end{cases}$$



In modelul de zgomot de tip **salt & pepper** exista doar doua valori posibile, a si b. Din aceasta cauza se mai numeste si zgomot de tip impuls (speckle). Probabilitatea de aparitie a fiecaruia este mai mica de 0.1 $\rightarrow$ la valori mai mari decat acestea, zgomotul va domina imaginea. Pentru o imagine de 8 biti, valoare de intensitate tipica pentru *zgomotul pepper* este ≈ 0 si pentru *zgomotul salt* este in jur de ≈ 255 .



Zgomot Salt &Pepper (sare si piper)





Zgomot Salt &Pepper (sare si piper)

Eliminarea zgomotului $\Rightarrow$ Filtru median (neliniar)

- Se pun intensitatile din vecinatatea pixeluului current $\text{Src}(i,j)$ intr-o lista
- Se aplica o statistica ordonata aspra elementelor din lista (sorteaza crescator)
- Se inlocuieste intensitatea pixelului $\text{Dst}(i,j)$ cu valoarea elementului median din lista sortata.

Exemplu:

- Se da o fereastră de dimensiune 3x3 cu urmatoarele intensitati:
- Se pun intensitatite intr-o lista:


110	110	114
100	106	104
95	88	85

{ 110, 110, 114, 100, **106**, 104, 95, 88, 85} , $\text{Src}(i,j) = 106$

- Se aplica statistica ordonata asupra listei vecinilor :

{85, 88, 95, 100, **104**, 106, 110, 110, 114}

- $\text{Dst}(i,j) = 104$ (intensitatea elementului median din lista)





Zgomot uniform


- Folosit pentru generarea oricarui alt tip de zgomot
- Folosit la degradarea imaginilor pentru evaluarea algoritmilor de restaurare (deoarece ofera un model de zgomot neutru)

Model

$$FDP_{Uniform} = \begin{cases} \frac{1}{b-a} & , a \leq g \leq b \\ 0 & , \text{altfel} \end{cases}$$

Media: $\mu = (a+b)/2$

Vrianta: $\sigma^2 = (b-a)^2/12$



Cu distributia uniforma, valorile nivelelor de gri ale zgomotelor sunt distribuite intr-un domeniu specific, care poate fi intreg domeniul (0 - 255 pentru 8 biti), sau o portiune mai mica din acest domeniu [a ... b].



Zgomot uniform



IMAGE PROCESSING



Zgomot gaussian

- Folosit pentru modelarea proceselor naturale care introduc zgomote (ex: zgomotul electric din timpul procesului de achizitie)
- Folosit pentru a modela si zgomotul datorat naturii discrete a radiatiei si procesului de conversie in semnal electric (detector/shot noise). Acest zgomot se datoreaza procesului de masurare (elementele fotosensibile numar particule (photoni) care sunt guvernate de legi statistice). Pentru modelarea acestui zgomot ar trebui folosita o distributie **poisson**, $\frac{u^n \exp(-u)}{n!}$, dar cu aceasta este dificil de lucrat (matematic) $\Rightarrow$ se aproximeaza printr-o distributie **gaussiana**

Model


$$FDP_{Gaussian} = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(g-\mu)^2}{2\sigma^2}}$$

unde:

g = nivel de gri;

μ = media zgomotului;

σ = deviatia standard a zgomotului;






Zgomot gaussian





Calculul nucleului gaussian – cazul 2D




FDP pt. zgomot gaussian cu medie 0:

$$G(x,y) = G(x)G(y)$$

$$G(x,y) = \frac{1}{2\pi\sigma^2} e^{-\frac{(x^2+y^2)}{2\sigma^2}}$$

Proiectarea unui nucleu de convolutie gaussian pentru restaurarea imaginilor corupte de zgomot gaussian cu deviatie standard σ si dimensiune w (variabile) :



$$G(x,y) = \frac{1}{2\pi\sigma^2} e^{-\frac{((x-x_0)^2 + (y-y_0)^2)}{2\sigma^2}}$$




Calculul nucleului gaussian – cazul 2D

Exemplu Matlab

```
function [G]=gaussian(sigma);  
w=round(6*sigma);  
x0=floor(w/2)+1;  
y0=x0;  
sigma2=2*sigma*sigma;  
for x=1:w  
    for y=1:w  
        G(x,y)=1/(pi*sigma2)*exp(-(x-x0)*(x-x0)+(y-y0)*(y-y0))/sigma2);  
    end  
end  
[X,Y] = meshgrid(1:.1:w,1:.1:w);  
Z = interp2(G,X,Y,'cubic');  
x=1:0.1:5;  
y=1:0.1:5;  
surf(x,y,Z);
```

$$\sigma = 0.8 \Rightarrow w = 5$$

```
G =  
    0.0005    0.0050    0.0109    0.0050    0.0005  
    0.0050    0.0521    0.1139    0.0521    0.0050  
    0.0109    0.1139    0.2487    0.1139    0.0109  
    0.0050    0.0521    0.1139    0.0521    0.0050  
    0.0005    0.0050    0.0109    0.0050    0.0005  
  
>> sum(sum(G))  
ans =  
    0.9982
```



1




Eliminarea zgomotului gaussian

Filtrare in domeniul spatial (cu nuclee de convolutie)

$$I_D(x, y) = G(x, y) * I_S(x, y)$$

sau

$$I_D(x, y) = (G(x)G(y)) * I_S(x, y) = G(x) * (G(y) * I_S(x, y))$$



$$G(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-x_0)^2}{2\sigma^2}}$$

$$G(y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y-y_0)^2}{2\sigma^2}}$$

Filtrare in domeniul frecventelor (Transformata Fourier) – vezi C7 si C8



Determinarea prezentei zgomotului in imagine

Raportul semnal zgomot (Signal to Noise Ratio - SNR) [1]

Modelul zgomotului aditiv:

$$f(i,j) = s(i,j) + n(i,j) \quad (1)$$

n – medie zero ($\langle n(i,j) \rangle = 0$) si independent de semnal ($\langle s(i,j)n(i,j) \rangle = 0$)

$\Rightarrow \langle s(i,j) \rangle = \langle f(i,j) \rangle = \mu \Rightarrow$ Zgomotul afecteaza deviatia standard (varianta) dar nu afecteaza media imaginii

$$\sigma_f^2 = \langle |f - \langle f \rangle|^2 \rangle = \langle |f|^2 \rangle - \langle f \rangle^2 \quad (2)$$

Din (1) + (2) $\Rightarrow$

$$\begin{aligned} \sigma_f^2 &= \langle |s + n|^2 \rangle - \langle s + n \rangle^2 \\ &= \langle |s|^2 + |n|^2 + 2|s||n| \rangle - (\langle s \rangle + \langle n \rangle)^2 \\ &= \langle |s|^2 \rangle - \langle s \rangle^2 + \langle |n|^2 \rangle \\ &= \sigma_s^2 + \sigma_n^2 \end{aligned}$$

$$SNR = \frac{\sigma_s}{\sigma_n} = \sqrt{\frac{\sigma_f^2}{\sigma_n^2} - 1}$$

SNR > 20 Little visible noise

SNR $\approx$ 10 Some noise visible

SNR $\approx$ 4 Noise clearly visible

SNR $\approx$ 2 Image severely degraded


SNR $\approx$ 1 Is there an image?




SNR – Example [1]:




SNR = 1



SNR = 2



SNR = 4



SNR = 8




Calculul raportului semnal zgomot (SNR)

A. Dintr-o singura imagine

1. Se calculeaza σ_f pe toata imaginea ($f(i,j) = s(i,j) + n(i,j)$)
2. Se selecteaza o regiune cu intensitate uniforma $\sigma_s = 0$ (ex: zona de cer, apa, un perete uniform etc. si se calculeaza:

$$\sigma_f^2 = \sigma_s^2 + \sigma_n^2 = \sigma_n^2 \Rightarrow \sigma_f = \sigma_n$$





Calculul raportului semnal zgomot (SNR)

B. Din doua imagini succesive (in timp) ale aceleiasi scene:

$$f(i,j) = s(i,j) + n(i,j)$$
$$g(i,j) = s(i,j) + m(i,j)$$

- n si m au aceeasi FDP: au aceasi medie: $\langle n \rangle = \langle m \rangle = 0$ si deviatie standard $\langle |n|^2 \rangle = \langle |m|^2 \rangle = \sigma_n^2$
- n si m sunt necorelate intre ele si fata de semnal: ($\langle s(i,j)n(i,j) \rangle = 0$, $\langle s(i,j)m(i,j) \rangle = 0$), $\langle n(i,j)m(i,j) \rangle = 0$
- f si g necorelate ($\langle f(i,j)g(i,j) \rangle = 0$)

Corelatia normalizata dintre f si g :

$$c = \frac{\langle f - \langle f \rangle \rangle \langle g - \langle g \rangle \rangle}{(\langle |f - \langle f \rangle|^2 \rangle)^{\frac{1}{2}} (\langle |g - \langle g \rangle|^2 \rangle)^{\frac{1}{2}}}$$
$$c = \frac{\langle f - \langle f \rangle \rangle \langle g - \langle g \rangle \rangle}{\sqrt{\sigma_f^2} \sqrt{\sigma_g^2}}$$



Calculul raportului semnal zgomot (SNR)

B. Din doua imagini succesive (in timp) ale aceleiasi scene:

$$c = \frac{\langle f - \langle f \rangle \rangle \langle g - \langle g \rangle \rangle}{\sqrt{\sigma_f^2} \sqrt{\sigma_g^2}}$$

$$\sigma_f^2 = \sigma_g^2 = \sigma_s^2 + \sigma_n^2; \quad f = s + n; \quad g = s + m; \quad \langle n \rangle = \langle m \rangle = 0$$

$$c = \frac{\sigma_s^2}{\sigma_s^2 + \sigma_n^2}$$

$$\text{SNR} = \sqrt{\frac{\frac{\sigma_s^2}{\sigma_s^2 + \sigma_n^2}}{1 - \frac{\sigma_s^2}{\sigma_s^2 + \sigma_n^2}}} = \frac{\sigma_s}{\sigma_n}$$

$$\text{SNR} = \sqrt{\frac{c}{1 - c}}$$



[1] Noise in images, Lecture notes on Digital Image Analysis, Applied Optics Group, Department of Physics, University of Edinburgh.



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

Curs 10

Prelucrari pe imagini multinivel (grayscale) (V)

Detectia muchiiilor



La ce ne foloseste detectia de muchii ?


- Se pare ca sistemul vizual al omului foloseste muchiile ca elemente primare in procesul de recunoastere dupa care se infereaza informatii complexe legate de culoare/textura/forma
 - Este posibil sa recunoastem forme/obiecte doar pe baza conturului (ex. desene alb/negru, benzi desenate alb/negru in care este prezenta doar informatia de contur).
- ⇒ Detectia muchiilor este o etapa care poate fi folosita in analiza automata a imaginilor
- ⇒ Detectia muchiilor $\approx$ proces de segmentare

Segmentare := din informatia de nivel coborat a imaginii (pixeli / row data) ⇒ se extrage informatia de nivel ridicat:


- puncte de muchie ⇒ contur ⇒ trasturi de forma ⇒ analiza
- puncte de muchie ⇒ trasaturi pt. stereoreconstructie



Muchie := frontiera care separa doua regiuni de intensitate diferita (intensitatea variaza brusc intre cele doua regiuni).




Cum putem detecta o muchie?







Profilul intensitatii in puntele de muchie




(a)



(b)



(c)




(d)



Gradientul imaginii (derivata de ordin 1)

Gradientul unei functii 2D

$$\nabla f(x, y) = \begin{bmatrix} \nabla f_x \\ \nabla f_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x} \\ \lim_{\Delta y \rightarrow 0} \frac{f(x, y + \Delta y) - f(x, y)}{\Delta y} \end{bmatrix}$$



Pentru o imagine digitala: $\Delta x = \Delta y = 1$

$$\nabla f(x, y) = \begin{bmatrix} \nabla f_x \\ \nabla f_y \end{bmatrix} = \begin{bmatrix} f[x+1, y] - f[x, y] \\ f[x, y+1] - f[x, y] \end{bmatrix} \Rightarrow \begin{aligned} \nabla f_x &= f(x, y) * \begin{bmatrix} -1 & 1 \end{bmatrix} \\ \nabla f_y &= f(x, y) * \begin{bmatrix} -1 \\ 1 \end{bmatrix} \end{aligned}$$



Aproximari ale gradientului

Operatorul Roberts

$$\nabla f_x = f(x, y) * \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

$$\nabla f_y = f(x, y) * \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

Operatorul Prewitt

$$\nabla f_x = f(x, y) * \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$\nabla f_y = f(x, y) * \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

Operatorul Sobel

$$\nabla f_x = f(x, y) * \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$\nabla f_y = f(x, y) * \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$





Marimi caracteristice (ale gradientului)

Magnitudinea


$$|\nabla f(x, y)| = \sqrt{(\nabla f_x(x, y))^2 + (\nabla f_y(x, y))^2}$$

Directia

$$\theta(x, y) = \arctg\left(\frac{\nabla f_y(x, y)}{\nabla f_x(x, y)}\right)$$



Imaginea $|\nabla|$



Binarizare
prag T






Exemple


Left Image [1:1] (379,0,[253],[GM: 0])




Left Gradient Vertical Edges [1:1] (133,343,[0],[GM: 1])



Left Gradient Edges (Canny) [1:1] (421,100,[0],[GM: 0])



Left Horizontal Edges [1:1] (284,0,[0],[GM: 0])





Metoda Canny de detectie a muchiiilor

Caracteristici


- Maximizarea raportului semnal zgomot pt. o detectie corecta.
- Localizare buna la marcarea punctelor de muchie
- Minimizarea nr. de raspunsuri pozitive la o singura muchie (eliminarea non-muchiilor)

Algoritm

1. Filtrare zgomot cu un filtru Gaussian.
2. Calcul modulului si directiei gradientului (ex. Sobel)
3. Supresia non-maximelor
4. Trhresholding cu histereza



1. Filtrare Gaussiana



$$g(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{((x-x_0)^2 + (y-y_0)^2)}{2\sigma^2}}$$

$$g(x, y) = g(x) \cdot g(y)$$

$$g(x) = \frac{1}{\sqrt{2 \cdot \pi} \cdot \sigma} \cdot e^{-\frac{(x-x_0)^2}{2 \cdot \sigma^2}}$$

$$g(y) = \frac{1}{\sqrt{2 \cdot \pi} \cdot \sigma} \cdot e^{-\frac{(y-y_0)^2}{2 \cdot \sigma^2}}$$

Exemplu: $\sigma = 0.8 \Rightarrow w = 5$ (latime filtrului) $w \approx 6 \cdot \sigma$

$$G(x,y) = \begin{bmatrix} 0.0005 & 0.0050 & 0.0109 & 0.0050 & 0.0005 \\ 0.0050 & 0.0521 & 0.1139 & 0.0521 & 0.0050 \\ 0.0109 & 0.1139 & 0.2487 & 0.1139 & 0.0109 \\ 0.0050 & 0.0521 & 0.1139 & 0.0521 & 0.0050 \\ 0.0005 & 0.0050 & 0.0109 & 0.0050 & 0.0005 \end{bmatrix}$$

$$f(x, y) = f_s(x, y) * g(x, y) = (f(x, y) * g(x)) * g(y)$$



2. Calcul modul si directie gradient

$$\nabla f(x, y) = \begin{bmatrix} \nabla f_x \\ \nabla f_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$$

$$\nabla_{f_x}(x, y) = f(x, y) * S_x(x, y)$$

$$\nabla_{f_y}(x, y) = f(x, y) * S_y(x, y)$$

$$S_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

Magnitudinea

$$|\nabla f(x, y)| = \sqrt{(\nabla f_x(x, y))^2 + (\nabla f_y(x, y))^2}$$

Directia


$$\theta(x, y) = \arctg\left(\frac{\nabla f_y(x, y)}{\nabla f_x(x, y)}\right)$$



3. Supresia non-maximelor

⇒ Subtierea muchiilor de-a lungul directiei gradientului (1 pixel grosime)

Cuantificarea directiei gradientului:



Exemplu: Presupunem ca avem un punct in care gradientul are directia “3”

P este un maxim local daca:

$$|\nabla_6| < |\nabla| \text{ and } |\nabla_2| < |\nabla|$$

Unde: $|\nabla|$, $|\nabla_2|$, $|\nabla_6|$ sunt magnitudinile gradientului in P, I_2 , I_6 .

Daca P este maxim local se retine. Altfel se elimina.




4. Thresholding cu histereza

⇒ Unirea punctelor de muchie de pe un contur (defragmentarea conturului)

1. Se folosesc doua praguri: θ_L (low) si θ_H (high) si se aplica urmatoarea schema de binarizare:

- Fiecare punct cu magnitudinea sub θ_L se eticheteaza ca *non-muchie* (non-edge).
- Fiecare punct cu magnitudinea peste θ_H se eticheteaza ca punct de *muchie-tare* (strong edge)
- Fiecare punct cu magnitudinea cuprinsa intre θ_L si θ_H se eticheteaza ca punct de *muchie-slaba* (weak edge)

2. Se aplica un algoritm similar celui de etichetare pentru marcarea punctelor de muchie slabe daca acetsea sunt conexe cu puncte de muchie tari si eliminarea acelor care nu sunt conexe cu puncte de muchie tari:



a. Rezultatul dupa pasul 1: muchii “tari” si muchii “slabe”. b. Rezultatul dupa pasul 2



4. Thresholding cu histereza


O implementare eficientă a pasului 2 folosește o coadă pentru a ține coordonatele punctelor de muchie tare. Algoritmul (BFS) rulează astfel:

1. Parcurge imaginea de la stânga la dreapta și de sus în jos și găsește primul punct de MUCHIE_TARE și pune coordonatele sale în coadă.
2. Cât timp coada nu este vidă
 - Extrage primul punct din coadă
 - Găsește toți vecinii de tip MUCHIE_SLABĂ ai acestui punct
 - Marchează în imagine vecinii acestui punct ca puncte de MUCHIE_TARE
 - Pune coordonatele acestor puncte în coadă
 - Continuă cu următorul punct din coadă
3. Continuă de la pasul 1 cu următorul punct de MUCHIE_TARE.
4. Elimină toate punctele de MUCHIE_SLABĂ din imagine, dându-le valoare NON_MUCHIE.



Rezultate

Imaginea $|\nabla|$



Supresia
non-
maximelor




Binarizare
cu
histereza





Operatori de ordin 2 (derivata a 2-a)



$$\begin{aligned}
 f_x'' &= (f_x')' = \frac{f'(x + \Delta x) - f'(x)}{\Delta x} = \\
 &= \frac{f(x + 2\Delta x) - f(x + \Delta x) - (f(x + \Delta x) - f(x))}{\Delta x^2} \\
 &= \frac{f(x + 2\Delta x) - 2f(x + \Delta x) + f(x)}{\Delta x^2}
 \end{aligned}$$

Inlocuim in ec. de mai sus pe x cu $x - \Delta x$:

$$f_x'' = \frac{f(x + \Delta x) - 2f(x) + f(x - \Delta x)}{\Delta x^2}$$

$$f_y'' = \frac{f(y + \Delta y) - 2f(y) + f(y - \Delta y)}{\Delta y^2}$$

Laplacianul

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} = f * \begin{bmatrix} 0 & 0 & 0 \\ 1 & -2 & 1 \\ 0 & 0 & 0 \end{bmatrix} + f * \begin{bmatrix} 0 & 1 & 0 \\ 0 & -2 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\nabla^2 f(x, y) = f * \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$



Operatori de ordin 2 (derivata a 2-a)

Alte forme ale laplacianului

- prin includerea in ec. de mai sus si a directiilor diagonale:

$$\nabla^2 f(x, y) = f * \begin{bmatrix} 0 & 0 & 0 \\ 1 & -2 & 1 \\ 0 & 0 & 0 \end{bmatrix} + f * \begin{bmatrix} 0 & 1 & 0 \\ 0 & -2 & 0 \\ 0 & 1 & 0 \end{bmatrix} + f * \begin{bmatrix} 1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 1 \end{bmatrix} + f * \begin{bmatrix} 0 & 0 & 1 \\ 0 & -2 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

$$\nabla^2 f(x, y) = f * \begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

- prin utilizarea negativului laplacianului:

$$\nabla^2 f(x, y) = -\left(\frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}\right)$$



$$\nabla^2 f(x, y) = f * \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix} \quad \nabla^2 f(x, y) = f * \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$



Laplacianul Gaussianului (LoG/ Mar-Hilderth)

$$h(x, y) = \nabla^2[g(x, y) \otimes f(x, y)]$$

$$h(x, y) = [\nabla^2 g(x, y)] \otimes f(x, y)$$





Figure 5.11: The *inverted* Laplacian of Gaussian function, $\sigma = 2$, in one and two dimensions.


$$LoG(x, y) = \nabla^2 g(x, y) = \frac{\partial^2 g(x)}{\partial x^2} \cdot g(y) + g(x) \cdot \frac{\partial^2 g(y)}{\partial y^2}$$

$$LoG(x, y) = \frac{-1}{2 \cdot \pi \cdot \sigma^6} \cdot (\sigma^2 - x^2) \cdot e^{-\frac{x^2}{2 \cdot \sigma^2}} \cdot e^{-\frac{y^2}{2 \cdot \sigma^2}} +$$
$$+ \frac{-1}{2 \cdot \pi \cdot \sigma^6} \cdot e^{-\frac{x^2}{2 \cdot \sigma^2}} \cdot (\sigma^2 - y^2) \cdot e^{-\frac{y^2}{2 \cdot \sigma^2}}$$

$$LoG(x, y) = \frac{x^2 + y^2 - 2\sigma^2}{2 \cdot \pi \cdot \sigma^6} \cdot e^{-\frac{x^2 + y^2}{2 \cdot \sigma^2}}$$



Laplacianul Gaussianului (LoG)



Aplicatie: stereo corelatie
(compenseaza variatia de
luminozitate dintre camera stanga si
dreapta).









Detectia muchiiilor folosind LoG

⇒ Detectia trecerilor prin zero ale derivatei a 2-a $\{f(x,y) \otimes \text{LoG}(x,y)\}$:

Discriminarea intre trecerile prin 0 ale f'' care corespund unui max. al $|f'|$ fata de puncte de inflexiune ($f''=0$ dar $|f'|$ nu e maxim ⇒ f' schimbare de semn)



Imaginea 2D a unui contrur intr-o vecinatate de 3x3 in jurul pixelului curent (u,v)

Determinarea pozitiei trecerii prin 0 a f'' la nivel de sub-pixel:

$$\text{Dc. } \text{LoG}(u,v) \cdot \text{LoG}(u+1,v) < 0: \quad du = \frac{\text{LoG}(u,v)}{\text{LoG}(u,v) + \text{LoG}(u+1,v)}$$

$$\text{Dc. } \text{LoG}(u,v) \cdot \text{LoG}(u,v+1) < 0: \quad dv = \frac{\text{LoG}(u,v)}{\text{LoG}(u,v) + \text{LoG}(u,v+1)}$$




Detectia muchiiilor folosind LoG

Discriminarea trecherilor prin 0 ale f''


Cazul $f'(u,v) * f'(u+1,v) < 0$ si $f'(u,v) * f'(u,v+1) < 0$

$\Rightarrow$ Daca f' are o schimbare de semn (punct de inflexiune) $\Rightarrow$ **SE ELIMINA**

Cazul $f' > 0$



Cazul $f' < 0$



Etapă finală: thresholding cu histereza




Detectia muchilor folosind LoG

Rezultate



$\sigma = 1.0$



$\sigma = 4.0$


Procesarea Imaginilor

Curs 11

**Inferarea informațiilor metrice
din imagini monoculare și stereo**

Modelul perspectivă (pinhole) al camerei (recapitulare C2)

Apertura / diafragma sunt approximate cu un punct (centrul de proiecție) $\Rightarrow$ principiul coliniarității modelului cu lentile subțiri (constrângerea 3)



Ecuatiile fundamentale ale modelului perspectivă al camerei sunt [Trucco1998]:

$$\begin{cases} x = f \cdot \frac{X_C}{Z_C} \\ y = f \cdot \frac{Y_C}{Z_C} \end{cases}$$


Unde: $[X_C, Y_C, Z_C]$ sunt coordonatele punctului $\mathbf{P}$ în sistemul de coordonate al camerei

$[x, y, -f]$ sunt coordonatele punctului $\mathbf{p}$ în sistemul de coordonate al camerei

Parametrii intrinseci ai camerelor

Descriu caracteristicile optice și geometrice ale camerei (caracteristicile interne ale camerei):

- *distanța focală* – distanța dintre centrul optic al sistemului de lentile al obiectivului și planul imagine: f ;
- *punctul principal* – coordonatele centrului real al imaginii (intersecția axei optice a obiectivului cu planul imagine) în coordonate imagine (pixeli) : (u_0, v_0) ;
- *coeficienții de distorsiune radială și tangențială* ai lentilelor obiectivului.



Parametrii extrinseci

Poziția și orientarea sistemului de coordonate 3-D asociat camerei relativa la sistemul de coordonate asociat lumii

Necesari pentru a transforma coordonatele unui punct din sistemul de coordonate al lumii in sistemul de coordonate al camerei și invers)

Vectorul de translație $\mathbf{T} = [T_x, T_y, T_z]^T$;

Vectorul de rotație $\mathbf{r} = [R_x, R_y, R_z]^T$ sau *matricea de rotație* echivalentă $\mathbf{R} = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix}$

În sistemele stereo cu mai multe camere, parametrii extrinseci ne permit de asemenea să exprimăm și relația spațială dintre aceste camere.

Mapare directă completa (3D world) $\Rightarrow$ (2D image): proiecție

Matricea de proiecție:

$$\mathbf{P} = \mathbf{A} \cdot [\mathbf{R}_{WC} \mid \mathbf{T}_{WC}] \quad (1)$$

Punct 3D din lume de coordonate $[X_w, Y_w, Z_w]$

$$s \cdot \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} x_s \\ y_s \\ z_s \end{bmatrix} = \mathbf{P} \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2)$$

Obținerea coordonatelor imagine 2D:

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} x_s / z_s \\ y_s / z_s \end{bmatrix}$$

Mapare inversa completa (2D image) $\Rightarrow$ (3D world): reconstrucție

A. Metodă **aproximativă** de măsurarea a distanțelor cu o camera mono (scenariu specific)

Se poate realiza în anumite condiții simplificatoare:

- O_W (originea sistemului de coordonate al lumii) este proiecția pe planul orizontal (sol/podea/drum) a centrului optic al camerei (O_C)
- $O_W Z_W$ și $O_C Z_C$ sunt coplanare
- Înălțimea *height* și unghiul α de inclinare (pitch) ale camerei sunt fixe și cunoscute (exemplu de scenariu specific pt. camera de supraveghere – monitorizarea traficului de pe autostrada/sosea)

Date de intrare

Parametrii intrinseci ai camerei:

f_X = distanța focală în unități de pixeli orizontali

f_Y = distanța focală în unități de pixeli verticali

$p_0(u_0, v_0)$ = punctului principal

Parametrii extrinseci ai camerei

α = unghiul de inclinare al camerei (pitch)


height = înălțimea camerei față de planul orizontal

$p_1(u_1, v_1)$ = proiecția pe imagine a punctului curent (de măsurat) $P_1(X, 0, Z)$ din planul orizontal

$p_2(u_2, v_2)$ = proiecția pe imagine a unui punct $P_2(X, Y, Z)$ aflat la o înălțime Y deasupra punctului P_1

Date de ieșire

Coordonatele 3D ale punctelor P_1 și P_2 în sistemul de coordonate al lumii.



1. Se va realiza mai intai **o proiectie laterala** pe planul $Y_W O_W Z_W$ (side-view) a punctelor din scena ($X_W = 0$) (fig. de mai jos). Punctul P_1 se proiecteaza in P_{10} , p_1 se proiecteaza in p_{10} , P_2 se proiecteaza in P_{20} etc.

Calculul unghiului facut de segmentul $[O_C P_{10}]$ cu axa optica a camerei se obtine din relatiile trigonometrice scrise in triunghiul $O_C P_{10} p_0$:

$$\gamma = \tan^{-1} \left(\frac{v_1 - v_0}{f_Y} \right) \quad (3)$$

Calculul adancimii Z al punctului P_1 (respectiv P_{10}) in sistemul de coordonate al lumii se deduce din triunghiul $\Delta O_C O_W P_{10}$:


$$Z = [O_w P_{10}] = \frac{height}{\tan(\alpha + \gamma)} \quad (4)$$

In mod anlogic se calculeaza coordonatele (inaltimea) punctului P_2 (respectiv P_{20}). Din triunghiul dreptungic $\Delta O_{CP_{20}P_0}$ se deduce:

$$\theta = \tan^{-1} \left(\frac{v_2 - v_0}{f_Y} \right) \quad (5)$$

Din triunghiul dreptunghic $\triangle O_C Y_2 P_{20}$ se deduce:

$$YY = [O_C O_W] - [O_C Y_2] = height - Z \cdot \tan(\alpha + \theta) \quad (6)$$



2. Offsetul lateral X al punctului P_1 fata de axa $O_W Z_W$ se poate deduce realizand **proiectia de sus** (top view sau bird-eye view) a scenei pe planul orizontal $X_W O_W Z_W$:

Din asemanarea triunghiurilor dreptunghice $\Delta O_W p_{10} p_1$ si $\Delta O_W P_{10} P_1$:

$$X = [P_1 P_{10}] = [p_1 p_{10}] \cdot \frac{[O_W P_{10}]}{[O_W Z_1]} = \frac{(u_1 - u_0)}{[O_W Z_1]} \cdot Z \quad (7)$$

Lungimea segmentului $[O_W Z_1]$ (unde Z_1 este proiectia punctului p_{10} pe planul orizontal) se deduce din proiectia laterala (side-view):

$$[O_W Z_1] = [Y_1 p_{10}] = [O_C p_{10}] \cdot \cos(\alpha + \gamma) = \frac{f_Y}{\cos(\gamma)} \cdot \cos(\alpha + \gamma) \quad (8)$$


Din (7) si (8):

$$X = \frac{(u_1 - u_0)}{f_Y} \cdot \frac{Z}{\cos(\alpha + \gamma)} \cdot \cos(\gamma) \quad (9)$$

Valoarea lui X se poate deduce si din vederea in perspectiva a scenei (prima figura de sus), scriind relatia de asemanare dintre triunghiurile $\Delta O_C p_{10} p_1$ si $\Delta O_C P_{10} P_1$ rezultand relatia (10) care este echivalenta cu (9):

$$X = \frac{(u_1 - u_0)}{f_Y} \sqrt{height^2 + Z^2} \cdot \cos(\gamma) \quad (10)$$

Nota: la camerele actuale se poate considera $f_x = f_y = f$ [pixeli] !



B. RECONSTRUCTIA PRIN STEROVIZIUNE

Ec. fundamentale ale modelului pinhole:

$$\begin{aligned}x &= f \cdot \frac{X}{Z} \\ y &= f \cdot \frac{Y}{Z}\end{aligned} \quad (11)$$

P(X,Y,Z) punct 3D in sist. coord. al camerei
p(x,y,-f) proiecția pe planul imagine


Plecând de la (x, y) putem estima doar ecuația dreptei de proiecție dar nu și adâncimea Z !!!

Măsurarea lui Z ⇒ Stereoviziune

Configurații sisteme stereo:

1. Canonica (cu axe paralele) - model teoretic imposibil de obținut practic ⇒ rectificarea imaginilor
2. Cu axe coplanare (neparalele) – model teoretic
3. Generala

Modelul unui sistem de stereoviziune (binocular)



Setul complet al parametrilor unui sistem de stereoviziune:

Grup parametri	Tip parametri	Set parametri
Parametrii interni ai sistemului stereo	Parametrii intrinseci (un set / camera)	Punctele principale: $\mathbf{PP}_L(x_{0L}, y_{0L}), \mathbf{PP}_R(x_{0R}, y_{0R})$ Distanța focală: $\mathbf{f}_L(f_{xL}, f_{yL}), \mathbf{f}_R(f_{xR}, f_{yR})$ Coeficienții de distorsiune: - radială: $(k_1^L, k_2^L), (k_1^R, k_2^R)$, - tangențială: $(p_1^L, p_2^L), (p_1^R, p_2^R)$
	Parametrii extrinseci relativi (un set / sistem stereo)	$\begin{cases} \mathbf{T}_{rel} = \mathbf{R}_{CL}^T \cdot (\mathbf{T}_{CR} - \mathbf{T}_{CL}) \\ \mathbf{R}_{rel} = \mathbf{R}_{CL}^T \cdot \mathbf{R}_{CR} \end{cases}$
Parametrii externi ai sistemului stereo	Parametrii extrinseci absoluți (un set / camera)	<i>Pentru camerele individuale:</i> Vectorii de translație: $\mathbf{T}_{CL}, \mathbf{T}_{CR}$ Matricele de rotație: $\mathbf{R}_{CL}, \mathbf{R}_{CR}$ Vectorii de rotație (se pot deduce din matricele de rotație): $\mathbf{r}_{CL}, \mathbf{r}_{CR}$ <i>Pentru sistemul stereo (stereo-rig):</i> Vectorul de translație: $\mathbf{T}_{C-rig} = \mathbf{T}_{CL}$ Matricea de rotație: $\mathbf{R}_{C-rig} = \mathbf{R}_{CL}$ Vectorul de rotație: $\mathbf{r}_{C-rig} = \mathbf{r}_{CL}$


Etapele procesului de stereoviziune

1. Realizarea sistemului stereo prin montarea a doua camere pe un suport rigid (stereo-rig), in configurația dorita (posibila)
2. Calibrarea camerelor (parametrii intrinseci: f , punct principal; parametrii extrinseci: R_{CW} , T_{CW}).
3. Achiziția de perechi imagini sincrone (obligatoriu pt. scene dinamice / optionala pt. cele statice)
4. Rectificarea imaginilor (daca se dorește reconstrucție după modelul canonic).
5. Extragerea si selecția de trasaturi de interes din ambele imagini (muchii verticale sau pixeli in cazul reconstrucției dense.).
6. Realizarea corespondentei (matching) dintre trasaturile imaginii stânga si dreapta.
7. Calculul coordonatelor 3D ale punctului reconstruit in sistemul de coordonate al camerei/lumii.

Referinte stereoviziune

- [Pan1996] He-Ping Pan, "General Stereo Image Matching Using Symmetric Complex Wavelets", *Technology Park, Adelaide, Australia, 1996*.
- [Ramesh1996] J. Ramesh, R. Kasturi, B. G. Schunk, "Machine Vision", *McGraw-Hill, Inc., 1996*.
- [Trucco1998] E. Trucco, A. Verri, "Introductory techniques for 3D Computer Vision", *Prentice Hall, 1998*.

Reconstrucție 3D in cazul canonic și coplanar



Modelul stereo canonic (stânga). Ilustrare a procesului de proiecție a unui punct 3D pe cele două planuri imagine după o vedere top-view (dreapta).


Modelul canonic

$$\begin{aligned}
 x'_l &= LC_L \cdot \frac{C_L O}{P_W O} = f \cdot \frac{X_1}{Z_1} \\
 x'_r &= LC_R \cdot \frac{C_R O}{P_W O} = f \cdot \frac{X_2}{Z_2} \\
 d = x'_l - x'_r &= f \cdot \left(\frac{X_1}{Z_1} - \frac{X_2}{Z_2} \right) = f \cdot \frac{X_1 - X_2}{Z} = f \cdot \frac{b}{Z} \\
 Z &= \frac{f \cdot b}{d}
 \end{aligned} \tag{12}$$

Modelul coplanar (cu axe neparalele)

$$Z = \frac{f \cdot b}{d + f \cdot \tan(\theta)} \tag{13}$$

Reconstrucție 3D în cazul general



Parametrii intrinseci:

Distante focale

- Left camera: f_L .
- Right camera: f_R .

Puncte principale

- Left camera: $C'_L = (x_{CL}, y_{CL})$.
- Right camera: $C'_R = (x_{CR}, y_{CR})$.

Parametrii extrinseci

$$T_{CL} = \begin{bmatrix} X_{CL} \\ Y_{CL} \\ Z_{CL} \end{bmatrix}$$

$$R_{CL} = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix}$$

$$T_{CR} = \begin{bmatrix} X_{CR} \\ Y_{CR} \\ Z_{CR} \end{bmatrix}$$

$$R_{CR} = \begin{bmatrix} r'_{11} & r'_{12} & r'_{13} \\ r'_{21} & r'_{22} & r'_{23} \\ r'_{31} & r'_{32} & r'_{33} \end{bmatrix}$$

Problema reconstructiei 3D = maparea perechilor de puncte 2D (P_L , P_R) intr-un punct unic P_W :

$$\mathbf{P}_W = \begin{bmatrix} X_W \\ Y_W \\ Z_W \end{bmatrix}$$

Solutia:

$$\mathbf{P}_W = \mu \mathbf{R}_L * \begin{bmatrix} x_L - x_{CL} \\ y_L - y_{CL} \\ -f_L \end{bmatrix} + \mathbf{T}_{CL} \Leftrightarrow \begin{bmatrix} X_W \\ Y_W \\ Z_W \end{bmatrix} = \mu \mathbf{R}_L * \begin{bmatrix} x_L - x_{CL} \\ y_L - y_{CL} \\ -f_L \end{bmatrix} + \begin{bmatrix} X_{CL} \\ Y_{CL} \\ Z_{CL} \end{bmatrix}, \quad (14)$$

unde μ este un factor de scalare dependent de Z

$$\begin{bmatrix} x_L - x_{CL} \\ y_L - y_{CL} \\ -f_L \end{bmatrix} = \mu^{-1} \mathbf{R}_L^T * \begin{bmatrix} X_W - X_{CL} \\ Y_W - Y_{CL} \\ Z_W - Z_{CL} \end{bmatrix} \Leftrightarrow \begin{bmatrix} x_L - x_{CL} \\ y_L - y_{CL} \\ -f_L \end{bmatrix} = \mu^{-1} \begin{bmatrix} r_{11} & r_{21} & r_{31} \\ r_{12} & r_{22} & r_{32} \\ r_{13} & r_{23} & r_{33} \end{bmatrix} * \begin{bmatrix} X_W - X_{CL} \\ Y_W - Y_{CL} \\ Z_W - Z_{CL} \end{bmatrix} \quad (15)$$

$$\mu^{-1} = \frac{-f_L}{r_{13}(X_W - X_{CL}) + r_{23}(Y_W - Y_{CL}) + r_{33}(Z_W - Z_{CL})} \quad (16)$$

Inclocuind μ^{-1} in (15), se obtine:

Pt. camera stanga:

$$\begin{cases} x_L - x_{CL} = -f_L \frac{r_{11}(X_W - X_{CL}) + r_{21}(Y_W - Y_{CL}) + r_{31}(Z_W - Z_{CL})}{r_{13}(X_W - X_{CL}) + r_{23}(Y_W - Y_{CL}) + r_{33}(Z_W - Z_{CL})} \\ y_L - y_{CL} = -f_L \frac{r_{12}(X_W - X_{CL}) + r_{22}(Y_W - Y_{CL}) + r_{32}(Z_W - Z_{CL})}{r_{13}(X_W - X_{CL}) + r_{23}(Y_W - Y_{CL}) + r_{33}(Z_W - Z_{CL})} \end{cases} \quad (17)$$

Pt. camera dreapta:

$$\begin{cases} x_R - x_{CR} = -f_R \frac{r'_{11}(X_W - X_{CR}) + r'_{21}(Y_W - Y_{CR}) + r'_{31}(Z_W - Z_{CR})}{r'_{13}(X_W - X_{CR}) + r'_{23}(Y_W - Y_{CR}) + r'_{33}(Z_W - Z_{CR})} \\ y_R - y_{CR} = -f_R \frac{r'_{12}(X_W - X_{CR}) + r'_{22}(Y_W - Y_{CR}) + r'_{32}(Z_W - Z_{CR})}{r'_{13}(X_W - X_{CR}) + r'_{23}(Y_W - Y_{CR}) + r'_{33}(Z_W - Z_{CR})} \end{cases} \quad (18)$$

Pentru simplificare vom nota:

$$\begin{cases} x'_L = x_L - x_{CL} \\ y'_L = y_L - y_{CL} \\ x'_R = x_R - x_{CR} \\ y'_R = y_R - y_{CR} \end{cases} \quad (19)$$

D.p.d.v geometric (17) si (18) reprezintă cele doua drepte de proiecție ale punctului P.

Sistemul geometric (17) si (18) se poate aduce in forma următoare (20):

$$\mathbf{A} * \begin{vmatrix} X_W \\ Y_W \\ Z_W \end{vmatrix} = \mathbf{B} \Leftrightarrow \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ a_{41} & a_{42} & a_{43} \end{vmatrix} * \begin{vmatrix} X_W \\ Y_W \\ Z_W \end{vmatrix} = \begin{vmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{vmatrix}, \quad (20)$$

Unde:

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ a_{41} & a_{42} & a_{43} \end{vmatrix} = \begin{vmatrix} r_{13}x'_L + r_{11}f_L & r_{23}x'_L + r_{21}f_L & r_{33}x'_L + r_{31}f_L \\ r_{13}y'_L + r_{12}f_L & r_{23}y'_L + r_{22}f_L & r_{33}y'_L + r_{32}f_L \\ r'_{13}x'_R + r'_{11}f_R & r'_{23}x'_R + r'_{21}f_R & r'_{33}x'_R + r'_{31}f_R \\ r'_{13}y'_R + r'_{12}f_R & r'_{23}y'_R + r'_{22}f_R & r'_{33}y'_R + r'_{32}f_R \end{vmatrix} \quad (21)$$

si

$$\begin{vmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{vmatrix} = \begin{vmatrix} a_{11}X_{CL} + a_{12}Y_{CL} + a_{13}Z_{CL} \\ a_{21}X_{CL} + a_{22}Y_{CL} + a_{23}Z_{CL} \\ a_{31}X_{CR} + a_{32}Y_{CR} + a_{33}Z_{CR} \\ a_{41}X_{CR} + a_{42}Y_{CR} + a_{43}Z_{CR} \end{vmatrix} \quad (22)$$

Rezolvarea algebrica a sistemului (20) se poate realiza prin metoda celor mai mici pătrate:

$$\mathbf{X} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{B} \quad (23)$$

D.p.d.v. geometric soluția reprezintă mijlocul segmentului de lungime minimă ce unește cele doua drepte.

Realizarea corespondenței (corelației) dintre trăsăturile pereche din cele două imagini stereo.


Acest proces poartă denumirea de stereo-corelație (*stereo-matching*) și constă în punerea în corespondență a unui punct din imaginea stângă P_L cu corespondentul său din imaginea dreaptă P_R , unde P_L și P_R sunt proiecțiile imagine ale aceluiași punct 3D P_W . Există două abordări majore a acestei probleme:

- reconstrucția doar a unor *trăsături de interes* (de exemplu puncte de muchie , colturi etc.)
- reconstrucția tuturor punctelor din imagine (în măsura în care este posibil procesul de corelație pentru un anumit punct) – **reconstrucție „densă”**.

Reducerea spațiului de căutare este o modalitate crucială care permite realizarea corespondenței în timp real atât prin algoritmi software cât și hardware. În plus, se mărește robustețea procesului de corelare prin reducerea fals-pozitivelor (prin limitarea spațiului de căutare). *Reducerea spațiului de căutare* are la bază *constrângerile impuse de geometria epipolară*.

Noțiuni de geometrie epipolară

- Planul format de punctul 3D P_W și centrele optice O_L și O_R (fig. de mai jos) ale celor două camere se numește **plan epipolar**.
- **Linia epipolară** este dreapta de intersecție dintre planul epipolar și planul imagine. Unui punct 3D P_W îi vor corespunde două linii epipolare: e_L și respectiv e_R .
- Intersecția dreptei ce trece prin cele două centre optice O_L și O_R (*baseline*-ul) cu cele două planuri imagine se realizează în două puncte fixe (a căror poziție depinde numai de parametrii sistemului stereo) numite **puncte epipolare** (câte unul pentru fiecare cameră).
- Toate dreptele epipolare ale unei camere se intersectează în punctul epipolar corespunzător.



Principala constrângere a geometriei epipolare folosită la reducerea spațiului de căutare în procesul de stereocorelație afirmă că, pentru fiecare punct $\mathbf{P}_L(x_L, y_L)$ din imaginea stângă, corespondentul său din imaginea dreaptă $\mathbf{P}_R(x_R, y_R)$ se va găsi pe linia epipolară corespunzătoare $\mathbf{e}_R$ având următoarea ecuație (și reciproc):

$$a_R * x + b_R * y + c_R = 0 \quad (23)$$

Parametrii liniei epipolare $\mathbf{e}_R$ pot fi calculați cunoscând matricea fundamentală $\mathbf{F}$ [Tru98], estimabilă dacă se cunosc parametrii sistemului stereo:

$$\begin{bmatrix} a_R \\ b_R \\ c_R \end{bmatrix} = \mathbf{F} * \mathbf{P}_L \quad (24)$$

unde :

$$\mathbf{P}_L = \begin{bmatrix} x_L \\ y_L \\ 1 \end{bmatrix} \quad \text{- coordonatele omogene ale punctului } \mathbf{P}_L;$$

$$\mathbf{F} = \left(\mathbf{A}_R^{-1} \right)^T * \mathbf{E} * \mathbf{A}_L^{-1} \quad \text{- matricea fundamentală;} \quad (25)$$

$$\mathbf{E} = \mathbf{R}_{LR} * \mathbf{S} \quad \text{- matricea esențială;} \quad (26)$$

$\mathbf{A}_L, \mathbf{A}_R$ - matricele interne ale celor două camere

$\mathbf{R}_{LR} = \mathbf{R}_{CR}^T * \mathbf{R}_{CL}$ - matricea de rotație relativă din sistemul camerei din stânga în sistemul camerei din dreapta

$\mathbf{T}_{LR} = [T_x \ T_y \ T_z]^T = \mathbf{R}_L * (\mathbf{T}_R - \mathbf{T}_L)$ - este vectorul de translație relativă din sistemul camerei din stânga în sistemul camerei din dreapta


$$\mathbf{S} = \begin{bmatrix} 0 & -T_z & T_y \\ T_z & 0 & -T_x \\ -T_y & T_x & 0 \end{bmatrix} \quad (27)$$

Pentru **modelul canonic** (imagini rectificate): problema reducerii spațiului de căutare se simplifică semnificativ: perechile de linii epipolare $\mathbf{e}_L$ și $\mathbf{e}_R$ devin coliniare (paralele cu axa orizontală a planului imagine).


Procedura de stereocorelatie (matching)




Reconstrucție
densă (fiecare
pixel)




Reconstrucție
bazată pe muchii




Imaginea de muchii (stanga)




Fereastra (grayscale) corelata din imaginea stanga



Zona de cautare a potrivirii celei mai bune in imaginea dreapta



Fereastra (LOG) corelata din imaginea stanga




Zona de cautare a potrivirii celei mai bune in imaginea dreapta


Funcția de corelație

Orice metrica de “distanță”: SAD, SSD, corelație normalizată, etc.

$$SAD(x_R, y_R) = \sum_{i=-\frac{w}{2}}^{\frac{w}{2}} \sum_{j=-\frac{w}{2}}^{\frac{w}{2}} |I_L(x_L + i, y_L + j) - I_R(x_R + i, y_R + j)| \quad (28)$$




Detectia minimului global al funcției de corelație (SAD)




Rafinarea poziției minimului global cu precizie de sub-pixel

CALIBRAREA CAMERELOR

Majoritatea metodelor folosesc un obiect de calibrare planar sau tridimensional cu geometrie cunoscută, și pe care pot fi identificate cu ușurință/precizie anumite puncte de control prin analiza vederilor achiziționate ale acestui obiect.



Patron planar folosit
pentru calibrarea
parametrilor intrinseci



Tinte in forma de X folosite la
calibrarea parametrilor extrinseci

Procesul de estimare a parametrilor

Estimarea parametrilor interni și externi se face prin minimizarea erorii totale dintre imaginile m_i ale punctelor de control detectate din imaginea 2D și proiecțiilor $\bar{m}_i$ ale punctelor de control 3D, calculate folosind modelul camerei care include ca și variabile / necunoscute parametrii de estimat:

$$\|m_i - \bar{m}_i\|$$

Pentru n imagini date ale modelului (planului de calibrare) și pentru fiecare m puncte de control al fiecărui model presupunem că proiecțiile acestor puncte pe planul imagine sunt afectate de un zgomot identic și uniform distribuit (de obicei se consideră un zgomot gaussian cu media 0). Estimarea se poate realiza prin minimizarea sumei pătratelor distanțelor dintre vectorii coordonatelor măsurătorilor și modelului:

$$\sum_{i=1}^n \sum_{j=1}^m \|m_{ij} - \hat{m}(A, R_i, t_i, M_j)\|^2$$

$$\sum_{i=1}^n \sum_{j=1}^m \|m_{ij} - \check{m}(A, k_1, k_2, R_i, t_i, M_j)\|^2$$

$\hat{m}(A, R_i, t_i, M_j)$ este proiecția punctului M_j pe imaginea i , iar m_{ij} sunt coordonatele detectate ale proiecției punctului de control m_i pe planul imagine i .

Bibliografie

E. Trucco, A. Verri, *Introductory Techniques for 3-D Computer Vision*, Prentice Hall, 1998.

S. Nedevschi, R. Dănescu, F. Oniga, T. Marița, [Tehnici de viziune artificială aplicate în conducerea automată a autovehiculelor](#), Editura U.T. Press, Cluj-Napoca, 2012, pp. 7-59.



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor

Curs 12

Modele de culoare. Procesarea si segmentarea imaginilor color.



Achizitia imaginilor color


Senzori color

<http://www.siliconimaging.com/RGB%20Bayer.htm>

⇒ white balance, decodificare pattern Bayer


a) Bayer mask

For color photos, the majority of commercial digital color cameras use pixels covered with special color filters in the three primary colors red, green and blue.



decodificarea
pattern-ului Bayer

c) 3-CCD camera




direct

Imagine RGB



Achizitia imaginilor color

Decodificarea pattern-ului Bayer





Calitatea imaginii (Bayer pattern vs. 3CCD) ???



Spatiul de culoare: RGB

RGB $\Rightarrow$ Culoarea fiecărui pixel (atât pentru echipamentele de achiziție – **camere**) cât și pentru afișare (**TV, CRT, LCD**) se obține prin combinația a trei culori primare: **roșu**, **verde** și **albastru**. (**Red**, **Green** și **Blue**)

$\Rightarrow$ spațiu de culoare aditiv (**R+G+B** $\Rightarrow$ Alb)



Modelul de culoare RGB mapat pe un cub.

În acest exemplu fiecare culoare este reprezentată pe câte 8 biți (256 de nivele) (imagini bitmap RGB24). Numărul total de culori este $2^8 \times 2^8 \times 2^8 = 2^{24} = 16.777.216$.



+



+



=






Spatiul de culoare: CMY

CMY: spațiu de culoare complementar fata de RGB folosit la dispozitive de imprimare color.

CMY model diferential (“subtractive”):

Alb = absenta componentelor de culoare

Negru = C + M + Y



CMYK





Spatiul de culoare: **R****G****B** normalizat

Reduce dependenta de iluminare a culorii obiectului

Se poate aplica doar daca variatiile de intensitate sunt uniforme de-a lungul spectrului RGB

$$r = \frac{R}{R + G + B}, \quad g = \frac{G}{R + G + B}, \quad b = \frac{B}{R + G + B}$$

$$r + g + b = 1$$



Modele de culoare: HSV (HSI, HSB, HSL)

HSI: (H, S, I), $H=0 \dots 360^\circ$, $S=0 \dots 1$, $V=0 \dots 1$

Algoritmul de conversie:

$r = R/255$; // r : componenta R normalizata

$g = G/255$; // g : componenta G normalizata

$b = B/255$; // b : componenta B normalizata

$M = \max(r, g, b)$;

$m = \min(r, g, b)$;

$C = M - m$;

Value:

$V = M$;



Saturation:

If (C)

$S = C / V$;

Else // grayscale

$S = 0$;





Modele de culoare: HSV (HSI, HSB, HSL)

HSI: (H, S, I), $H=0 \dots 360^\circ$, $S=0 \dots 1$, $V=0 \dots 1$

Algoritmul de conversie:

Hue:

If (C) {

*if (M == r) H = 60 * (g - b) / C;*

*if (M == g) H = 120 + 60 * (b - r) / C;*

*if (M == b) H = 240 + 60 * (r - g) / C;*

}

Else // grayscale

H = 0;

If (H < 0)



H = H + 360;

Valorile pt. H, S si V calculate cu formulele de mai sus vor avea următoarele domenii de valori:

$H = 0 \dots 360$




$S = 0 \dots 1$

$V = 0 \dots 1$





Modele de culoare: HSI (HSV, HSB, HSL)



Reprezentare normalizata (in intervalul 0 .. 255) a valorilor lui Hue si a Saturatiei



Alte modele (liniare)

XYZ tristimulus - transformare liniara asupra RGB:

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} 0.607 & 0.174 & 0.200 \\ 0.299 & 0.587 & 0.114 \\ 0.000 & 0.066 & 1.116 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$



$$\begin{aligned} \text{sat} &= \sqrt{a^2 + b^2} , \\ \text{hue} &= \arctan'(b, a) \end{aligned}$$

CIE(Lab) space

$$\begin{aligned} L &= 25(100Y/Y_0)^{1/3} - 16 , \\ a &= 500 \left[(X/X_0)^{1/3} - (Y/Y_0)^{1/3} \right] \\ b &= 200 \left[(Y/Y_0)^{1/3} - (Z/Z_0)^{1/3} \right] \end{aligned}$$


CIE(Luv) space

$$\begin{aligned} u &= 13W(4X/(X + 15Y + 3Z) - 0.199) \\ v &= 13W(6Y/(X + 15Y + 3Z) - 0.308) \end{aligned}$$



L – componenta de intensitate

a, b - componentele de culoare cu variatie liniara





Proprietati ale trasaturilor cromatice

Invarianta la translatie si scalare (la variatii de iluminare)

Hue – invarianta la scalarea uniforma a RGB: $H(\alpha R, \alpha G, \alpha B) = H(R, G, B)$

RGB-norm – invarianta la scalarea uniforma RGB:

$$\begin{aligned}r(\alpha R, \alpha G, \alpha B) &= r(R, G, B) \\g(\alpha R, \alpha G, \alpha B) &= g(R, G, B) \\b(\alpha R, \alpha G, \alpha B) &= b(R, G, B)\end{aligned}$$

Hue – invarianta la translatia uniforma RGB: $H(R + \beta, G + \beta, B + \beta) = H(R, G, B)$

RGB-norm – **nu prezinta invarianta** la scalarea uniforma RGB:

$$\begin{aligned}r(R + \beta, G + \beta, B + \beta) &\neq r(R, G, B) \\g(R + \beta, G + \beta, B + \beta) &\neq g(R, G, B) \\b(R + \beta, G + \beta, B + \beta) &\neq b(R, G, B)\end{aligned}$$



Proprietati ale trasaturilor cromatice

Singularitate Hue pt. $R, G, B \approx 0$

$R \approx G \approx B \approx 0 \Rightarrow H$ nedefinit

Exemple:

$$H(1,0,0) = 0, H(0,1,0) = 120^\circ$$

$$H(1,1,0) \Rightarrow H(2,1,0) : \delta H = 30^\circ$$



Concluzie: calcularea H in zone cu intensitatea mica $\Rightarrow$ erori numerice



Procesari pe imagini color

Similare cu cele pe imagini grayscale

Procesarile se aplica pe fiecare componenta de culoare in parte.





Metoda Canny (imagini color)

[2] A. Koschan, M. Abidi, Digital Color Image Processing, Wiley & Sons, 2008.

Algoritm

1. Filtrare zgomot cu un filtru trece jos ([2], cap. 5.3, pp102-117)

2. Calculul modulului si directiei gradientului ([2], cap 6.1.1, pag 126-128)

3. Supresia non-maximelor

4. Thresholding cu histereza



Metoda Canny (imagini color)

Pas2 :

Pixel (x,y) $\Rightarrow$ culoarea : $C(x,y)=(R,G,B)$

Gradient pt. fiecare componenta de culoare $\Rightarrow$ **Jacobian** (matricea derivatelor parțiale ale vectorului C):

$$\mathbf{J} = \begin{pmatrix} R_x & R_y \\ G_x & G_y \\ B_x & B_y \end{pmatrix} = (\mathbf{C}_x, \mathbf{C}_y).$$

$$R_x = \frac{\partial R}{\partial x} \text{ and } R_y = \frac{\partial R}{\partial y}$$



Metoda Canny (imagini color)

Directia - vectorul propriu al $J^T J$ corespunzator celei mai mici valori proprii:

$$\tan(2\theta) = \frac{2 \cdot \mathbf{C}_x \cdot \mathbf{C}_y}{\|\mathbf{C}_x\|^2 - \|\mathbf{C}_y\|^2}$$




$$\mathbf{C}_x = (R_x, G_x, B_x)$$

Magnitudinea:

$$m^2 = \|\mathbf{C}_x\|^2 \cos^2(\theta) + 2 \cdot \mathbf{C}_x \cdot \mathbf{C}_y \cdot \sin(\theta) \cos(\theta) + \|\mathbf{C}_y\|^2 \sin^2(\theta).$$



Rezultate Canny [2]






Segmentarea imaginilor color

Segmentare := identificare zone omogene din imagine

Segmentare imagini color := identificare regiuni (componente conexe) care satisfac anumite criterii de omogenitate, bazate pe trasaturi derivate din componentele spectrale. Aceste componente sunt definite in spatiul de culoare considerat.

(1) Regiune (definitie bazata pe notiunea de pixel) := componenta conexa a unui set de pixeli specificata printr-o functie de aparteneta la o clasa definita in spatiul de culoare considerat:

- (a) Culoarea pixelului este intr-un semispatiu definit de un plan;
- (b) Culoarea pixelului se incadreaza intr-un poliedru;
- (c) Culoarea pixelului se incadreaza intr-o celula Voronoi data de niste puncte reprezentative;



Decompozitie (spatiu) Voronoi := In cazul cel mai simplu (2D) se dau un set de puncte S in plan (centre Voronoi). Fiecare centru s are asociata o celula Voronoi $V(s)$ continand toate punctele mai apropiate de s decat de toate celelalte centre.

Segmentele diagramei Voronoi sunt multimi de puncte (segmente de dreapta) care sunt egal departate de 2 centre (cele mai apropiate)

Nodurile Voronoi sunt puncte echidistante fata de 3 sau mai multe centre Voronoi



Segmentarea imaginilor color

(2) Regiune (definitie bazata pe notiunea de regiune) := setul maximal de pixeli pentru care este satisfacuta o conditie de uniformitate (predicat de omogenitate):

(a) Regiuni uniforme obtinute prin cersterea unui bloc/seed prin unirea altor pixeli sau blocuri de pixeli

(b) Regiuni uniforme obtinute prin impartirea unor regiuni mai mari care nu sunt omogene

(3) Regiune (definitie bazata pe notiunea de muchie) := set de pixeli delimitati de pixeli de muchie (countur) - (predicat de ne-omogenitate):

(4) Regiune := corespunde unei suprafete a unui obiect din material omogen (physics based vision methods – modele de reflexie bazate pe proprietatile materialelor)



1. Segmentare la nivel de pixel

Segmentare se face in spatiul trasaturilor (culorilor)


Abordari:

1. Bazate pe histograma: detectia maximelor si gruparea culorilor (clustering) in jurul maximelor + clasificarea pixelilor in aceste clustere
2. Clusering in spatiul de culoare – punctele din spatiul de culoare sunt grupate in jurul unor centre reprezentative + clasificarea pixelilor in aceste clustere



1.1. Segmentare bazata pe impartirea histogramei

Detectia maximelor histogramei Hue (filtrate) si impartirea spatiului Hue in Clusteri avand ca centre aceste varfuri + clasificare pixeli (vezi L3)





1.2 Clustering in spatiul de culoare

Gruparea culorilor (din spatiul culorilor) si asignarea ficarui grup a unei culori echivalente (medie)


- **cuantizare/posterizare** (impartirea spatiului trasaturilor in subspatii de dimensiuni fixe);

- **clustering**:

- info. apriori: se stiu nr. clusterelor / pozitiile centrelor (de exemplu varfurile histogramelor)


- fara informatii apriori

Nu se aplica de obicei pe RGB ci pe **HS** sau pe de preferat pe **ab** sau **uv** (*liniar*)





Exemplu: clustering in R^2



$X1$, $X2$ – pot fi cele doua axe de coordonate corespunzatoare componentelor de culoare: (H,S) sau (a,b) sau (u,v)



K-means clustering

K-means

Partitioneaza un set de ***n*** observatii (ex. culorile pixelilor in spatiul considerat) in ***k*** cluster, in care fiecare observatie va apartine de clusterul cu cel mai apropiat centru (medie).

Setul de observatii: (***x*1, *x*2, ..., *x*n**) , ***x*i** – vector *d*-dimensional (ex. pt. un spatiu bidimensional: ***x*i** = (*a*i, *b*i))

Scop $\Rightarrow$ *k* multimi ($k \leq n$) ***S*** = {*S*1, *S*2, ..., *S**k*} astfel incat sa minimizam suma patratelor distantelor de la fiecare punct din cluster la centrul (media) clusterului

$$\arg \min_{\mathbf{S}} \sum_{i=1}^k \sum_{\mathbf{x}_j \in S_i} \|\mathbf{x}_j - \boldsymbol{\mu}_i\|^2$$

μ_i – centroidul (media clasei *S*_{*i*})



K-means clustering

Algoritmul standard (Lloyd)

Pas 1: “initializare” - se da un set initial de centroide (medii/means):
 $m_1(1), \dots, m_k(1)$

Pas 2: “atribuire” – se atribuie fiecare observatie la clusterul cu centroidul (media) cea mai apropiata (se partitioneaza observatiile dupa diagrama Voronoi data de medii).

$$S_i^{(t)} = \left\{ \mathbf{x}_j : \|\mathbf{x}_j - \mathbf{m}_i^{(t)}\| \leq \|\mathbf{x}_j - \mathbf{m}_{i^*}^{(t)}\| \text{ for all } i^* = 1, \dots, k \right\}$$

Pas 3: “actualizare” – se reactualizeaza mediile fiecarui cluster pe baza observatiilor incorporate

$$\mathbf{m}_i^{(t+1)} = \frac{1}{|S_i^{(t)}|} \sum_{\mathbf{x}_j \in S_i^{(t)}} \mathbf{x}_j$$

Repeta pasii 2 si 3. Oprete cand se atinge convergenta (nu mai sunt schimbari sau se atinge un anumit numar de pasi/repetitii).




K-means clustering

Metode de initializare


- Forgy** – aleg aleator k observatii $\Rightarrow$ medii initiale
- Random partition** - initial asigneaza aleator un cluster la fiecare observatie
 - Mediile initiale: centroidele unor puncte alese aleator pt. fiecare cluster

Obs: pt. clusterring in spatiul de culoare (HS) sau (ab) sau (uv) se pot lua cele mai pronuntate K varfuri ale histogramei bidimensionale


Exemplu:




Pas 1: Initializare
k=3, centre alese
aleator



Pas 2:
Partitionare
Voronoi



Pas 3:
Recalculare
centriode



Repeta pasii 2 si 3
pana la
convergenta



Metrice de distanta

Exemple pt. cazul 2D:


- doua puncte $P_1 = (x_1, y_1)$ si $P_2 = (x_2, y_2)$

Distanta Euclidiană - distanta geometrica intre doua puncte in spatiul bidimensional definita ca linia dreapta care le uneste:

$$d_{Euclidian}(P_1, P_2) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} = \|P_1 - P_2\|$$

City block sau Manhattan - distanta este definita ca si calea de parcurgere prin unul din cei 4 vecini (sus, jos, stanga, dreapta - fara a parcurge ca directie diagonala intre pixeli):

$$d_{CityBlock}(P_1, P_2) = |x_2 - x_1| + |y_2 - y_1|$$



Chessboard sau Chebyshev (miscarea regelui pe tabla de sah) - parcurgerea se poate realiza in cele opt directii spatiale:

$$d_{Chessboard}(P_1, P_2) = \max(|x_2 - x_1|, |y_2 - y_1|)$$

Mahalanobis – distanta geometrica normalizata

$$d_{Mahalanobis}(P_1, P_2) = \sqrt{\frac{(x_1 - x_2)^2}{\sigma_x^2} + \frac{(y_1 - y_2)^2}{\sigma_y^2}}$$



2. Segmentare la nivel de regiune

- In spatiul imagine
- Criterii de uniformitate
- 1. Region Growing
- 2. Region Splitting
- 3. Split & merge

Se pot aplica atat pe imagini color (componente de culoare) cat si pe grayscale (intensitate)

Segmentarea imaginii prin Region Splitting (impartire)

- (1) Imparte imaginea in blocuri B de dimensiune $N \times N$; $N = 2^n$, n - rangul blocului.
 - (2) Pentru fiecare bloc:
 - (3) Dc. NEUNIFORMITATEA (B) $> T$ si $k = \text{rang}(B) > 0$; atunci
 - divide blocul B into 4 blocuri egale B1;B2;B3;B4;
 - repeta pasul (3) pt. B1;B2;B3;B4;
- Altfel raporteaza B ca un bloc aparte.



Metoda region growing are la baza un proces iterativ prin care regiuni ale imaginii sunt fuzionate incepand de la regiuni primare (care pot fi pixeli sau alte regiuni mici – celule de baza). Iteratiile de crestere se opresc atunci cand nu mai sunt pixeli de procesat !

Algorithm:

1. Se segmenteaza imaginea in celule de baza (dimensiune ≥ 1 pixel).
2. Fiecare celula este comparata cu vecinii ei folosind o masura de similaritate. In caz afirmativ (valoarea metricei de similaritate $<$ prag) celulele sunt fuzionate intr-un fragment mai mare (si se marcheaza ca si parcurse – ex. primesc eticheta regiunii) si se actualizeaza trasaturile regiunii folosite la masura similaritatii (de obicei prin mediere ponderata).
3. Se continua procesul de crestere al fragmentului prin examinarea tuturor vecinilor pana cand nu se mai pot realiza fuziuni.
4. Se trece la urmatoarea celula ramasa nemarcata si se repeta pasii 2-3. Algoritmul se opreste atunci cand nu au mai ramas celule nemarcate.



Exemplu de implementare

O implementare eficientă folosește algoritmul BFS si coadă FIFO (similar cu algoritmul omonim de etichetare):

1. Parcurge imaginea de la stânga la dreapta și de sus în jos și găsește primul seed point (celula de baza) și pune coordonatele sale în coadă si se stabileste o etichita unica pentru aceea regiune
2. Cât timp coada nu este vidă, repeta:
 - Extrage primul punct din coada
 - Găsește toți vecinii acestui punct care satisfac conditia de similaritate
 - Marchează în imagine vecinii acestui punct cu eticheta seed pointului initial
 - Pune coordonatele acestor puncte în coadă
 - Continuă cu următorul punct din coadă
3. Continuă de la pasul 1 cu următorul seed point (neparcurs inca).




Exemplu de implementare (grayscale)

Pt. fiecare punct (seed-point) nemarcat (x,y):

1. Se adauga elementul de start in lista FIFO si se seteaza indecsii de inceput si sfarsit ai listei (top , bottom), valorile initiale ale contoarelor pentru numarul curent de elemente din lista FIFO si pentru numarul curent de elemente (pixeli) din regiunea curenta:

- $bottom = 0$; //indexul celui mai vechi element din lista
- $top = 1$; // indexul la prima pozitie libera (din partea de sus a listei)
- $contor = 1$; // numarul de elemente din lista ($contor = top - bottom$)
- $N = 1$; // numarul curent de pixeli din regiune
- $Labels(x,y)=k$; // pixelul primeste eticheta k si simultan este marcat ca si parcurs/procesat ($Labels(x,y) \neq 0$)



2. repeat

- pentru fiecare vecin (i,j) al pixelului din pozitia „bottom” a listei:
 - daca $Labels(i,j) \neq 0$ (pixel neprocesat inca) si $abs(I(i,j) - I_{avg}) < T$:
 - adauga pixelul (i,j) in lista FIFO in pozitia top: $top++$; $contor++$; $N++$;
 - pixelul (i,j) primeste eticheta k (este adaugat la regiunea curenta si este marcat ca procesat: $Labels(i,j)=k$
 - se actualizeaza valoarea medie a regiunii:
$$I_{avg} = \frac{N * I_{avg} + I(i, j)}{N + 1}$$

- sterge elementul de pe pozitia bottom a listei FIFO: $bottom++$; $contor--$;

until ($contor = 0$) //lista FIFO devine goala ($top=bottom$)




Region Growing - examples

RG in spatiul (H,S) cu 1
seed point selectat manual



RG in spatiul (R,G,B)





- [1] W. Skarbek, A. Koschan, Colour Image Segmentation: A Survey, Technical report 94-32, Technische Universitat Berlin, Fachbereich 13 Informatik Franklinstrasse 28/29, 10587 Berlin, Germany
- [2] A. Koschan, M. Abidi, Digital Color Image Processing, Wiley & Sons, 2008.
- [3] http://en.wikipedia.org/wiki/K-means_clustering



Technical University of Cluj - Napoca
Computer Science Department

Procesarea Imaginilor








Curs 13

Texturi: Caracterizarea si extragera trasaturilor texturale




Textura

Definitie := trăsătura ce caracterizează distribuția spațială sau repetitivă a nivelelor de intensitate/culoare ale suprafețelor obiectelor / zonelor de interes.



Caracteristici:

- Contrastul
- Direcționalitatea
- Regularitatea
- Finețea
- Asperitatea
- Netezimea
- Granulația
- Incidența
- Alinierea
- Irregularitatea
- etc.





Caracterizarea texturilor

Metodele de extragere a trăsăturilor texturale ale imaginilor sunt clasificate în 4 categorii:

- structurale**: utilizează **primitive** pentru descrierea elementelor de textură și găsirea **regulilor de descriere** a **relațiilor spațiale** dintre elemente; aceste metode sunt potrivite pentru expunerea structurilor de tip **macro regulate**.



Textura macro-regulata

- statistice**: sunt potrivite pentru texturi de tip '**micro**'. Se identifică astfel taxonomia tehnicilor statistice bazate pe: **funcții de corelație**, **operatori pe muchii**, **matrice pe nivele de gri de tip 'co-occurrence'**, **grey-level run-lengths** și **modele autoregresive** la care se adaugă măști de filtrare de tip **trăsături de tip Law's energy**, **sume a nivelelor de gri** și **diferența histogramelor**.



Textura micro

- **analiza în domeniul de frecvențe** (FT, FFT, CT)

- **tehnici bazate pe modele** ca și câmpurile Markov și **fractali**



Trasaturi statistice de ordin 1

Media nivelelor de gri - o masura a intensitatii medii a imaginii/regiunii de interes (ROI). O valoare mare arata o imagine/regiune cu luminozitate ridicata, in timp ce o valoare mica indica o imagine/regiune intunecata.

$$\mu = \sum_{g=0}^L g \cdot p(g) = \frac{1}{M} \sum_{g=0}^L g \cdot h(g) = \frac{1}{M} \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} I(i, j)$$

Deviatia standard - masura a contrastului unei imaginii/regiunii de interes (ROI). O valoare mare arata o imagine/regiune cu contrast ridicat (histograma latita), in timp ce o valoare mica indica o imagine/regiune cu contrast ridicat scazut (histograma ingusta).


$$\sigma = \sqrt{\sum_{g=0}^L (g - \mu)^2 \cdot p(g)} = \sqrt{\frac{1}{M} \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} (I(i, j) - \mu)^2}$$

Energia – masura a numarului de nivele de gri din imagine/ROI. O valoare scazuta indica un numar mare de nivele de intensitate in timp ce o valoare mare indica un numar scazut de nivele de intensitate (valoarea maxima 1 indica un singur nivel de intensitate).

$$E = \sum_{g=0}^L [p(g)]^2$$

Entropia – este o masura a informatiei medii a imaginii (nr. de nivele de gri din imagine $\approx$ nr. de biti necesari pentru a codifica imaginea). O valoare mare indica faptul ca intensitatile pixelilor sunt distribuite pe toata plaja de valori ($H_{MAX} = \log_2 L$ – FDP uniforma).

$$H = - \sum_{g=0}^L p(g) \cdot \log_2 p(g)$$





Trasaturi statistice de ordin 2

Matricea de coocurenta a nivelurilor de gri (GLCM)

⇒ construirea unei matrici care sa contorizeze numarul de perechi de pixeli, avand doua valori distincte ale intensitatii, situati la o anumita distanta ***d*** unul fata de celalalt.

Fie ***D = {(dx dy)}*** - un set de vectori de deplasament ($dx=dy \approx 1 \dots 2$)

Un element al matricii de coocurenta a nivelelor de gri calculeaza cardinalul (#) setului ***S*** al pixelilor care iau doua valori distincte, ***g1*** si ***g2***, ale intensitatii si sunt situati la distanta ***(dx, dy)*** unul fata de celalalt:

$$C_D(g_1, g_2) = \#\{(x,y), (x',y')\}: f(x,y)=g_1, f(x',y')=g_2, x=x'+dx, y=y'+dy\}$$

Pentru a se putea face comparatia intre texturi din imagini de dimensiuni / rezolutii diferite, in practica se utilizeaza matricea **GLCM normalizata**:

$$p(g_1, g_2) = \frac{C_D(g_1, g_2)}{\sum_{g_1=0}^{G-1} \sum_{g_2=0}^{G-1} C_D(g_1, g_2)}$$



Trasaturi statistice de ordin 2

Trastauri GLCM

Contrastul (inertia) - descrie modul de variatie al nivelurilor de intensitate ale texturii :

$$Contrast = \sum_i \sum_j (i-j)^2 p(i, j)$$

Analizand structura matricii de coocurenta a nivelurilor de gri, putem obtine informatii cu privire la contrast:

- valori mari apropiate de diagonala principala si valori mici spre margini inseamna **contrast scazut**
- valori mici apropiate de diagonala principala si valori mari spre margini inseamna **contrast ridicat**

Omogenitatea locala - caracterizeaza textura din punctul de vedere al omogenitatii (uniformitatii) valorilor de intensitate, fiind cu atat mai mare cu cat diferenta intre doua valori de intensitate i, j , ale unor pixeli situati la distanta (dx, dy) unul fata de celalalt, este mai mica.

$$Homogeneity = \sum_{i=0}^{G-1} \sum_{j=0}^{G-1} \frac{1}{1 + (i - j)^2} p(i, j)$$



Trasaturi statistice de ordin 2

Corelatia exprima gradul de dependenta a valorilor de intensitate i, j din imagine, situate la distanta (dx, dy) unele fata de celelalte, probabilitatea de aparitie a perechii (i, j) fiind $p(i, j)$.

$$Corelation = \frac{\sum_{i=0}^{G-1} \sum_{j=0}^{G-1} (i - \mu_x)(j - \mu_y)p(i, j)}{\sigma_x \sigma_y}$$

Unde: $\mu_x = \sum \sum_{i, j} ip(i, j)$ - media valorilor dupa prima componenta

$\mu_y = \sum \sum_{i, j} jp(i, j)$ - media valorilor dupa cea de-a doua componenta

$\sigma_x^2 = \sum \sum_{i, j} p(i, j) (i - \mu_x)^2$ - dispersia valorilor pentru prima componenta

$\sigma_y^2 = \sum \sum_{i, j} p(i, j) (j - \mu_y)^2$ - dispersia valorilor pentru a doua componenta.



Trasaturi statistice de ordin 2

Momentul unghiular de ordinul 2, sau **energia totala** - se defineste ca fiind suma patratelor probabilitatilor de aparitie a doi pixeli de valori ale intensitatii i, j , situati la distanta d unul fata de celalalt.

$$\text{Total_energy} = \sum_i \sum_j (p(i, j))^2$$

Energia este, in acest context, opusul entropiei. In acest sens, ea reprezinta **ordinea**, de aceea energia este utilizata in texturi pentru **masurarea gradului de ordonare al texturii**.

Entropia - gradul de incertitudine in intalnirea a doua valori, i si j , in cadrul aceleiasi texturi.

$$\text{Entropy} = - \sum_i \sum_j p(i, j) \log_2 p(i, j)$$



Trasaturi statistice de ordin 2

Umbrirea clusterilor:





$$\text{Cluster shade} = \sum_i \sum_j (i + j - \mu_x - \mu_y)^3 p(i, j)$$

Proeminenta clusterilor:

$$\text{Cluster proeminence} = \sum_i \sum_j (i + j - \mu_x - \mu_y)^4 p(i, j)$$



Trasaturi statistice de ordin 2





Trasaturi statistice de ordin 2

Functia / matricea de autocorelatie a nivelelor de gri

Prin intermediul functiei de autocorelatie se poate determina gradul de regularitate al texturii, precum si granularitatea acesteia. Functia de autocorelatie se defineste prin urmatoarea expresie:

$$\rho(x, y) = \frac{\sum_{u=0}^N \sum_{v=0}^N I(u, v) I(u + x, v + y)}{\sum_{u=0}^N \sum_{v=0}^N I^2(u, v)}$$

Functia de autocorelatie data mai sus este extinsa pentru a forma o **matrice de autocorelatie** cu x, y in domeniul 0 to $N-1$ unde $N \times N$ este dimensiunea imaginii sau regiuni de inters sau a clusterului de imagine analizat.



Trasaturi statistice de ordin 2

Trasaturi bazate pe matricea de autocorelatie a nivelelor de gri

Asperitatea – este in legatura cu dimensiunile primitivelor din imagine. Pentru texturi fine, primitivele sunt mici, astfel incat se vor repeta mai des.

$$Coarseness = \frac{\sum_i \sum_j Max(i, j)}{n} + \frac{\sum_i \sum_j Max(i, j)}{m}$$

unde $Max(i, j) = 1$ daca elementul (i, j) din matricea de autocorelatie este fie un maxim pe linii sau pe coloane si $n \times m$ este dimensiunea matricii de autocorelatie

Busyness – indica o masura a vitezei de variatie a intensitatilor in imagine. Parametrul α este ales astfel incat valoarea asperitatatii sa fie semnificativa fata de 1.

$$Busyness = 1 - Coarseness^{\frac{1}{\alpha}}$$

Contrast – indica a masura a gradului de claritate a contururilor / muchiilor din imagine



$$Contrast = \frac{M_a \times N_t \times Coarseness^{\frac{1}{\alpha}}}{n \times m}$$

unde:

- M_a este modulul mediu al gradientului functiei de autocorelatie
- N_t este numarul de puncte cu modulul mai mare decat un prag t . Pragul t este setat la mijlocul intervalului de definitie al modulelor matricii



Trasaturi statistice de ordin 2



Calculul parametrilor Busyness si Coarsness pe
o zona normala (stanga) si pe tumoare (dreapta)



Trasaturi bazate pe modele – distanta fractala

Metoda **Box-Counting** de estimare a dimensiunii fractale pentru semnale 3D (imagini grayscale)

1. Se selectează o regiune de interes din imagine (dimensiune $M \times M$, $M = 2^n$)
2. Se setează rezoluția de calcul:
 - rezoluția minimă: R_i (2^{R_i} va fi numărul minim de sub-blocuri în care se împarte regiunea de interes, ceea ce corespunde unui sub-bloc de dimensiune maximă $2^{\max}$, $0 < \min < \max < n$)
 - rezoluția maximă: R_s (2^{R_s} va fi numărul maxim de sub-blocuri în care se împarte regiunea de interes, ceea ce corespunde unui sub-bloc de dimensiune minimă $2^{\min}$, $0 < \min < \max < n$)
3. Pt. fiecare rezoluție de calcul se împarte regiunea de interes considerată în sub-blocuri de dimensiune $2^k < 256$, $0 < \min < k < \max$). De asemenea se împarte spațiul nivelelor de intensitate în sub-blocuri de dimensiune 2^k , rezultând un spațiu cuantificat 3D cu blocuri cuboidale cu latura 2^k
4. Pentru fiecare bloc (i,j) în spațiul de coordonate (x,y) al imaginii se calculează nivelul minim și maxim de intensitate al pixelilor din acest bloc, se identifică numărul/indicele sub-blocurilor corespunzătoare: $g_{\min}$ și $g_{\max}$ și se determină grosimea „cuverturii” de nivele de gri ce acoperă imaginea:

$$n(i, j) = g_{\max} - g_{\min} + 1$$



Metoda Box-Counting

5. Se calculează numărul de blocuri necesare pentru a acoperi întreaga imagine, $N(k)$:


$$N[k] = \sum_{i,j} n(i, j)$$

6. Dacă s-a setat o singură rezoluție de calcul se calculează dimensiunea fractală după formula:

$$DF = - \frac{\log(N[k])}{\log(2^k)}$$

7. Dacă s-au setat mai multe rezoluții de calcul, atunci se interpolează liniar perechile de puncte obținute: $(x_k, y_k) = (\log(2^k), \log(N[k]))$ prin metoda celor mai mici pătrate, obținându-se o dreaptă de interpolare: $y = mx + n$. Dimensiunea fractală va fi chiar panta acestei drepte (luată cu semn schimbat):


$$DF = -m$$



Divizarea regiunii de interes în sub-blocuri cuboidale pentru calculul dimensiunii fractale prin metoda *Differential-Box-Counting*



Dimensiunea fractala



Calculul dimensiunii fractale prin metod Box-Counting pe o regiune selectata in afara tumorii (stanga), respectiv pe o regiune selectata in interiorul tumorii (dreapta).


Exemple de subiecte date la examen

1. Definiți/explicați noțiunile de mai jos:


- Planul epipolar, liniile epipolare, punctele epipolare.
- Disparitatea (în contextul stereoviziunii) și modul ei de calcul.
- Definiți proiecția orizontală și verticală a pixelilor unui obiect (din imagini binare- alb&negru).
- Contrastul mediu al imaginii și modul de cuantificare.
- Prin ce se caracterizează gradientul într-un punct al imaginii. Prezentați metoda/formulele de calcul.
- Supresia non-maximelor (în contextul metodei Canny de detecție a muchiilor).
- Filtrul median și aplicabilitate.
- Cum se poate mari viteza (reduce timpul) de procesare pentru filtrarea gaussiană ? Dați exemple.
- Cum se poate calcula media și deviația standard a nivelurilor de intensitate ale unei imagini parcurgând imaginea doar o singură dată? Exemplificați!

2. Prezentați în detaliu un algoritm de calcul automat al pragului de binarizare pentru imagini grayscale cu histograma bimodală.

3. Prezentați o metodă de detecție a centrelor obiectelor de tip “+” din imaginea alăturată. (celelalte obiecte trebuie excluse din analiză). Metoda trebuie să fie complet automată (nu se admite specificarea unor parametrii de intrare de la utilizator). Prezentați/explicați în detaliu fiecare pas/etapă.



4. Pentru imaginea alaturata, desenati histograma imaginii si propuneti un algoritm de segmentare (identificati fiecare patch = set de pixeli conecși cu intensitate asemănătoare) bazat pe analiza histogramei. Se presupune că nu există 2 patchuri cu intensități asemănătoare în imagine.



5. Prezentați o metoda de detectie a colturilor interioare (intersectia a 2 patrate albe cu 2 patrate negre pentru figura de mai jos. Prezentați/explicați în detaliu fiecare pas/etapa.

